Üretici, Yayıncı ve Yeniden Yazım Kayması Altında LLM Tarafından Üretilmiş Siber Tehdit İstihbaratının Tespiti: Çok Ajanlı Bir Çalışma

Furkan Çolak

***Özet*—Uydurma siber tehdit istihbaratı (CTI), onu kullanan bilgi tabanlarını ve modelleri zehirleyebilir; büyük dil modelleri (LLM) de böyle bir metni ucuza üretmeyi mümkün kılıyor. Bu çalışmada üretici, yayıncı veya metnin kendisi değiştiğinde LLM tarafından üretilmiş CTI'ın insan yazımı raporlardan ayrılıp ayrılamadığını sınıyoruz. İnsan parçaları ChatGPT'den önce yayımlanmış CISA belgelerinden ve test için ayrılan Microsoft ve Mandiant yazılarından geliyor. Üç ajanlı bir hat (Analist, Yazar, Editör), beş model ailesinden beş üreticiye aynı çıkarılmış olgulardan yeni metinler yazdırıyor; bu metinlerden on iki yeniden yazım, prompt ve kısmi üretim koşulu türetiliyor. Tespit de ajanlara bölünmüş durumda: TF-IDF modelleri, bir stilometrik model, ince ayarlı RoBERTa ve bir LLM yargıç, yığınlanmış bir Koordinatör'ü besliyor; Fast-DetectGPT ve Binoculars eğitimsiz referans olarak kullanılıyor. Aynı üreticide F1 0.998 oluyor. Görülmemiş 120B bir modelde bir TF-IDF dedektörünün F1 değeri 0.329 düzeyine düşüyor, ROC-AUC değeri ise 0.979 olarak kalıyor. Bir yerine üç üreticiyle eğitim bu F1 değerini 0.883 düzeyine çıkarıyor, ama aynı dedektörün Microsoft parçalarındaki yanlış pozitif oranını da 0.003 değerinden 0.152 değerine yükseltiyor. Yalnızca insan skorlarından belirlenen bir eşik de aynı bedeli ödetiyor. Hata analizi nedenini gösteriyor: kaçırılan metinler CISA parçaları gibi uzun, kişisiz ve sözcük çeşitliliği düşük metinler; yanlışlıkla işaretlenen firma parçaları ise eğitim üreticilerinin metinleri gibi daha kısa, birinci şahısla yazılmış ve sözcük çeşitliliği yüksek. Doğrulama verisiyle kalibrasyon, üretici kayması altında olasılıkları kötüleştiriyor. Bir LLM ile yeniden ifade eğitimsiz dedektörlerin duyarlılığını düşürüyor, eğitilmiş olanlarınkini değiştirmiyor; kaynaktan yeniden yazım ve cümle düzeyinde karıştırma ikisini de düşürüyor. Koordinatör 22 senaryonun 13 tanesinde RoBERTa'dan iyi, en çok ağırlık verdiği üyenin çöktüğü 5 senaryoda ondan kötü.**

***Anahtar Kelimeler*—siber tehdit istihbaratı, makine üretimi metin tespiti, büyük dil modelleri, çok ajanlı sistemler, kalibrasyon, alan kayması**

I. Giriş

Siber tehdit istihbaratı (CTI) saldırgan grupları, zararlı yazılımları, istismar edilen zafiyetleri ve bunlardan çıkan savunma adımlarını anlatır. Bu metinleri analistler okur, makineler de işler. Göstergeler ve anlatılar bilgi grafiklerine dönüştürülür, tespit kurallarına çevrilir, başka modelleri eğitmek veya yönlendirmek için kullanılır. Bu akışa giren sahte bir rapor, hiçbir insanı kandırmadan da zarar verebilir. Ranade ve arkadaşları GPT-2'yi CTI ile ince ayardan geçirdi. Tehdit avcıları üretilen raporları gerçekleri kadar güvenilir buldu ve sahte metinle bir siber güvenlik bilgi grafiği zehirlendi [1]. Huang ve arkadaşları daha büyük bir LLM'i siber güvenlik metniyle ince ayardan geçirdi ve insan değerlendiricilerin bu modelin CTI'ını gerçek raporlardan ayıramadığını buldu [2]. Qian ve arkadaşları veri zehirlemeyi taklit etmek için sahte CTI'ı gerçek derlemlere kattı [3]. Bugünkü LLM'ler bu ince ayarlı modellerden daha uzun ve akıcı metin yazıyor ve çoğu ücretsiz kullanılabiliyor.

Makine üretimi metin tespiti etkin bir araştırma alanı, ancak kanıtların çoğu haber, kompozisyon, ürün yorumu ve soru-cevap verisinden geliyor [4]–[6]. Bu çalışmaların üç sonucu burada önemli. Bir üreticiyle eğitilen dedektörler başka üreticilerde doğruluk kaybediyor ve görülmemiş üreticilerin metnini insan yazımı sayma eğiliminde [4], [5]. Üretilmiş bir metnin ikinci bir modelle yeniden ifade edilmesi birçok dedektörü atlatıyor [7], [8]. Eğitim dağılımından farklı insan yazımı, örneğin anadili İngilizce olmayan yazarların metni, çok daha sık makine üretimi sayılıyor [9]. Bildiğimiz kadarıyla bu üç sonucun hiçbiri CTI üzerinde sınanmadı; CTI ise bu sonuçları değiştirebilecek biçimde olağan veri setlerinden ayrılıyor. Özel ad ve tanımlayıcı yoğunluğu yüksek, metin yayımlayan kurumun üslubunu izliyor ve tek bir rapor çoğu zaman kısa parçalara bölünüp alıntılanıyor.

Mevcut CTI çalışmalarının her biri tek bir ince ayarlı üretici kullanıyor ve dedektörleri o üreticinin çıktısında deniyor [1]–[3]. Bir dedektör eğitilmediği bir model ailesiyle, daha büyük bir modelle, başka bir kurumun raporuyla veya üretimden sonra yeniden yazılmış bir metinle karşılaştığında ne olduğunu göstermiyorlar. Böyle bir kaymadaki başarısızlığın, dedektörün sinyali kaybetmesinden mi yoksa karar eşiğinin artık uymamasından mı kaynaklandığını da göstermiyorlar. İki durumun çaresi farklı: ilkinde yeni eğitim verisi, ikincisinde yeni bir eşik gerekiyor. Bu yüzden yalnızca sabit eşikteki F1 değerini veren bir çalışma, dedektörü işleten kişiye ne yapması gerektiğini söyleyemiyor.

Bu soruları, bu amaçla kurduğumuz bir derlem üzerinde inceliyoruz. İnsan parçaları ChatGPT'den önce yayımlanmış CISA belgelerinden ve aynı dönemin, ana eğitim kümelerine girmeyen Microsoft ve Mandiant yazılarından geliyor. LLM sürümlerini bir ajan hattı yazıyor. Analist her parçanın olgularını bir kez çıkarıyor, her üretici için bir Yazar ve bir Editör yeni metni yalnızca bu olgulardan oluşturuyor. Böylece bütün üreticiler aynı içeriği anlatıyor ve hiçbiri insan ifadesini görmüyor. Üreticiler arasındaki bir farkı yazım farkı olarak okuyabiliyoruz. Tespit de farklı kanıtlara bakan ajanlara bö-

Bu çalışma, Kırşehir Ahi Evran Üniversitesi'nde Dr. Öğr. Üyesi Gülsüm Akkuzu Kaya'nın yürüttüğü Bilgi Güvenliği yüksek lisans dersi için hazırlanmıştır.

F. Çolak, Kırşehir Ahi Evran Üniversitesi, Fen Bilimleri Enstitüsü, Bilgisayar Mühendisliği Anabilim Dalı yüksek lisans öğrencisidir, Kırşehir, Türkiye (e-posta: colak.furkan@ogr.ahievran.edu.tr; furkancolakofficial@gmail.com).

lünmüş durumda (kelime ve karakter n-gram'ları, stilometrik istatistikler, ince ayarlı bir kodlayıcı, talimatla eğitilmiş bir LLM yargıç) ve bir Koordinatör bunları birleştiriyor. Literatürden eğitim gerektirmeyen iki dedektör, Fast-DetectGPT [10] ve Binoculars [11], dış referans noktası olarak kullanılıyor.

Sınanan hipotez **H1**: İnsan yazımı ve LLM tarafından üretilmiş CTI, makine öğrenmesi modellerinin aynı üretici içinde ve üreticiler arasında kullanabileceği istatistiksel ve dilsel farklar taşır. Makalenin dört katkısı var.

1) Beş model ailesinden beş üreticinin aynı çıkarılmış olgulardan yazdığı, içeriği denetlenmiş bir CTI derlemi kuruyoruz. Hepsi 30 Kasım 2022 veya öncesinde yayımlanmış üç yayıncının insan metni, üretici kaymasını yayıncı kaymasından ayırıyor; test parçalarına on iki yeniden yazım, prompt stratejisi ve kısmi üretim koşulu uygulanıyor. Bütün bölmeler kaynak rapor düzeyinde yapılıyor.
2) Kayma altında sıralamayı ve kararı ayrı ayrı ölçüyoruz. Üç kalibratör ve beş eşik kuralı yalnızca doğrulama verisiyle kuruluyor; kurallardan ikisi test üreticisi hakkında hiçbir varsayım yapmıyor. Sonuç şu: görülmemiş bir üretici için işe yarayan iki çare, havuzlanmış eğitim verisi ve insan skorlarından belirlenen eşik, başka bir yayıncının insan metninde yanlış alarmı artırıyor.
3) Dedektör ajanlarını birleştirmenin ne zaman yardımcı olduğunu sınıyoruz. Yığınlanmış Koordinatör, kayma altında en iyi tutunan üye olan RoBERTa ile 22 senaryoda, kaynak düzeyinde eşleştirilmiş aralıklar ve Holm düzeltmesiyle karşılaştırılıyor. Dört Koordinatör çeşidi birleşimin neden geride kaldığını gösteriyor; her dedektörün çıkarım maliyeti ölçülüyor.
4) İki hata türünü de taban oranlarına göre inceliyoruz. Kaçırılan LLM metinleri ve yanlışlıkla işaretlenen insan metinleri, doğru sınıflandırılanlarla uzunluk, sözcük çeşitliliği, özel ad oranı, birinci şahıs kullanımı ve sözcüksel modelin en çok ağırlık verdiği n-gram'lar bakımından karşılaştırılıyor; analiz kategoriler, örnekler ve standart hataları kaynağa göre kümelenmiş regresyonlar içeriyor.

Bölüm II ilgili çalışmaları ve bu çalışmanın onlardan farkını anlatıyor. Bölüm III ve IV veriyi ve ajanları, Bölüm V deney düzenini, Bölüm VI sonuçları veriyor. Bölüm VII nedenleri ve uygulamadaki kullanımı, Bölüm VIII sınırlılıkları tartışıyor.

II. İlgili Çalışmalar

A. Denetimli ve sıfır örnekli dedektörler

İlk dedektörler token istatistiklerine dayanıyordu. GLTR, örneklenmiş metnin yüksek sıralı tokenlarda yoğunlaştığını gösterdi ve bunu insan okurlara yardım için kullandı [12]. RoBERTa [13] gibi önceden eğitilmiş kodlayıcılar üzerinde ince ayar yapılan sınıflandırıcılar GPT-2 çıktısını yüksek doğrulukla yakaladı [14]. İnce ayarlı kodlayıcılar ortak görevlerde hâlâ güçlü bir referans [15]. Eğitim gerektirmeyen yöntemler bir metni referans bir dil modeliyle puanlıyor. DetectGPT bir pasajın log-olasılığını bozulmuş kopyalarınınkiyle karşılaştırıyor [16]. Fast-DetectGPT bozma adımının yerine modelin kendi koşullu dağılımlarından örneklemeyi koyuyor ve yazarlarının koşullu olasılık eğriliği dediği büyüklüğü puanlıyor. Yazarlar bunun 340 kat hızlı olduğunu bildiriyor [10]. Binoculars bir metnin bir modeldeki şaşkınlığını iki yakın model arasındaki çapraz şaşkınlığa bölüyor ve böylece promptun kendisinin ne kadar şaşırtıcı olduğunu normalleştiriyor [11]. Ghostbuster birkaç zayıf modelden gelen token olasılıklarını doğrusal bir sınıflandırıcıya veriyor ve alanlar arasında iyi genelliyor [17]. Özellik modelleri artık hizmet verilmeyen OpenAI modelleri olduğu için onu yeniden üretemedik.

B. Genelleme, saldırılar ve kısmi üretim

M4 birden çok üretici, alan ve dil içeriyor ve dedektörlerin görülmemiş üreticilerin metnini çoğu zaman insan yazımı olarak etiketlediğini bildiriyor [4]. RAID, görülmemiş üreticilerin, kod çözme ayarlarının ve saldırgan düzenlemelerin çoğu dedektörü yanılttığını gösteriyor [5]. DetectRL test koşullarını üretilmiş metnin uygulamada kullanılma biçimlerinden, yeniden ifade ve insan ile makine metninin karıştırılması dahil, kuruyor [6]. Krishna ve arkadaşları bir yeniden ifade modelinin birkaç dedektörü atlattığını gösteriyor [7]; Sadasivan ve arkadaşları ulaşılabilecek en iyi AUROC değerini insan ve makine dağılımları arasındaki uzaklığa bağlıyor [8]. RADAR, yeniden yazımla atlatılmasını zorlaştırmak için dedektörü bir yeniden ifade modeline karşı eğitiyor [18]. Metnin yalnızca bir kısmı üretildiğinde görev, SemEval-2024 Görev 8'de olduğu gibi insan ve makine cümleleri arasındaki sınırı bulmaya dönüşüyor [15], [19]. Dedektörler eğitim verisinden farklı insan metninde de yanılıyor: anadili İngilizce olmayan yazarların metni anadili İngilizce olanlarınkinden çok daha sık işaretleniyor [9].

C. Topluluklar ve çok ajanlı tespit

Yığınlanmış genelleme, ikinci düzey bir modeli birinci düzey modellerin çıktıları üzerinde eğitir [20]. Ong ve Quek birkaç DetectGPT sınıflandırıcısının çıktısını birleştiriyor ve üretici bilinmediğinde tek başına DetectGPT'den yüksek bir AUROC bildiriyor [21]. İki yeni sistem tespiti iş birliği yapan LLM ajanlarına veriyor. CAMF'de üç ajan bir metnin üslubunu, anlam tutarlılığını ve akıl yürütmesini çıkarıyor, iki ajan bu profiller arasındaki tutarsızlıklar üzerine karşılıklı tartışıyor ve bir yargıç karar veriyor [22]. AGENT-X bir metni dilbilimsel yönergeleri uygulayan uzman ajanlara yönlendiriyor ve karar eşiğine ihtiyaç duymuyor [23]. İkisi de eğitim yapılmadan, prompt verilen LLM'lerle kurulmuş ve genel alan veri setlerinde (haber, kompozisyon, öykü, soru-cevap) GPT-3.5, GPT-4 ve Claude modellerinin metinleriyle değerlendirilmiş. Bu yüzden eğitilmiş dedektörlerin öğrenilmiş bir birleşimi hakkında, özellikle de böyle bir birleşimin üretici değiştiğinde üyelerine karşı üstünlüğünü koruyup korumadığı hakkında fazla bir şey söylemiyorlar.

D. Kayma altında kalibrasyon

Modern sinir ağı sınıflandırıcıları çoğu zaman aşırı güvenli ve sıcaklık ölçekleme dağılım içinde basit bir çözüm [24]. Platt ölçekleme [25], izotonik regresyon [26] ve sıcaklık ölçekleme eğitim dağılımından ayrılmış veriyle kuruluyor. Veri kümesi kayması altında dağılım içi veriyle yapılan kalibrasyon

bozuluyor ve az koruma sağlayabiliyor [27]. Kalibrasyon hatası genellikle kutulanmış beklenen kalibrasyon hatası [28], Brier skoru ve negatif log-olabilirlik ile ölçülüyor. Metin tespitinde uygulamada karşılaşılan durum, yeni bir üreticide ROC-AUC değeri yüksek kalırken F1 değeri düşen bir dedektör. Bu durumda sorunun eşikte olup olmadığını ve o üreticiden veri olmadan onarılıp onarılamayacağını soruyoruz.

E. LLM'ler ve CTI

Ranade ve arkadaşları veri zehirleme için ince ayarlı GPT-2 ile sahte CTI üretti [1]. Huang ve arkadaşları bir LLM'i alan verisiyle ince ayardan geçirdi, değerlendiricilerin onun CTI'ını gerçek raporlardan ayıramadığını gösterdi ve bu metin üzerinde yanlış bilgi dedektörlerini karşılaştırdı [2]. Qian ve arkadaşları sahte CTI üretmek için genel bir dil modelini ince ayardan geçirdi ve onu bulmak için BERT ve TextCNN tabanlı bir sınıflandırıcı önerdi [3].

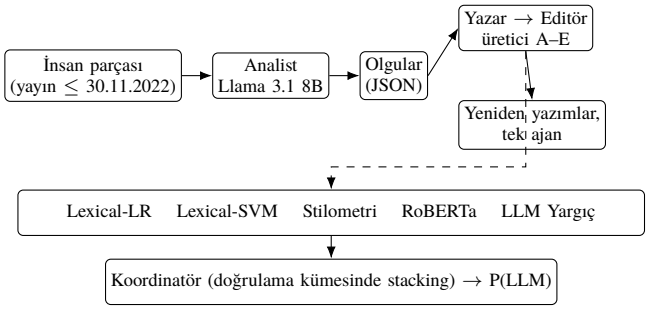
F. Bu çalışmanın farkı

Yukarıdaki CTI çalışmaları tek bir ince ayarlı üretici, tek bir insan metni kaynağı ve sabit bir karar eşiği kullanıyor. Bu çalışma dört noktada ayrılıyor. (i) Üretim içerik açısından denetleniyor: beş aileden beş üretici aynı çıkarılmış olgulardan yazıyor ve hiçbiri insan ifadesini görmüyor. Böylece üreticiler arası sonuçlar konuyla karışmıyor. (ii) Kayma üç ayrı eksende sınanıyor: üretici (görülmemiş aileler ve daha büyük modeller), yayıncı (ana eğitim kümelerinde hiç kullanılmayan Microsoft ve Mandiant insan metni) ve yeniden yazım (yeniden ifade, geri çeviri, "insanlaştır" promptu, prompt stratejileri ve cümle düzeyinde karıştırma). Karşılaştırmalar kaynak düzeyinde eşleştirilmiş istatistiklerle yapılıyor. (iii) Kalibrasyon ve eşik seçimi, sıralamadan ayrı bir soru olarak ele alınıyor ve her kurulum yalnızca eğitim ve doğrulama verisiyle yapılıyor. (iv) Çok ajanlı dedektörün yardımcı olduğu varsayılmıyor. Senaryo senaryo, kayma altındaki en güçlü üyesiyle karşılaştırılıyor. Yanında yayımlanmış iki sıfır örnekli dedektör ve bir maliyet ölçümü var. Genel alan veri setleri [4]–[6] bizden daha çok üretici ve saldırı kapsıyor. Kapsamadıkları şey, tanımlayıcıların, kurum adlarının ve kurum üslubunun sinyalin büyük kısmını taşıdığı CTI dili.

III. Veri

A. İnsan yazımı CTI

CISA (eğitim, doğrulama ve test). Kamu malı olan CISA siber güvenlik bildirimlerini, analiz raporlarını ve uyarılarını topladık. Sayfalar yalnızca son revizyon tarihini gösterdiği için yayın tarihini bildirim kodundan veya URL'den okuduk. İnsan yazarlığı konusunda şüphe kalmaması için ChatGPT kamuya açılmadan önce, 30 Kasım 2022 veya öncesinde yayımlanmış belgeleri tuttuk. Üretici yama duyuruları ve katalog güncellemeleri dışarıda bırakıldı. Her sayfadan en az 20 kelimelik anlatı paragraflarını (<p>) aldık. Tabloları, kodu, gösterge listelerini ve kalıp metinleri attık. Ardışık paragrafları boşlukla ayrılmış 150–350 kelimelik parçalar hâlinde birleştirdik (kaynak başına en çok 3 parça). Sonuçta 203 kaynak ve 406 parça elde edildi. Her kaynağa anahtar kelime kurallarıyla bir konu etiketi verildi (APT, fidye yazılımı, oltalama, zafiyet, zararlı yazılım, diğer). Tablolardaki kelime sayıları stilometrik özelliklerin saydığı alfabetik tokenlardır ve biraz daha düşüktür.



Şekil 1. Üretim ajanları (üstte) ve tespit ajanları (altta). Bütün üreticiler aynı Analist olgularından yazar ve insan parçasını hiç görmez. Yeniden yazılmış sürümler Yazar–Editör çıktısından başlar; tek ajan koşulu insan parçasını doğrudan okur. İnsan parçaları CISA'dan (eğitim ve test) ve Microsoft ile Mandiant'tan (yalnızca test) gelir.

Microsoft ve Mandiant (yalnızca bağımsız test). Dedektörlerin başka bir kurumun yazım üslubunu LLM yazarlığıyla karıştırıp karıştırmadığını sınamak için aynı tarih sınırıyla iki firma kaynağı topladık: Microsoft Security Blog ve artık Google Cloud üzerinde yayımlanan Mandiant tehdit istihbaratı blogu. Microsoft için blogun kendisinin içerik türünü *Research*, konusunu *Threat intelligence* olarak etiketlediği yazıları tuttuk. Ürün haberleri ve en iyi uygulama yazıları dışarıda kaldı. Microsoft sayfa üst verileri revizyon geçmişini değil yakın tarihli bir site taşımasının değiştirme tarihlerini gösteriyor. Bu yüzden yazıları URL'deki yayın tarihine göre tarihledik ve sonraki güncellemeleri duyuran paragrafları (örneğin yeniden adlandırılmış tehdit aktörleri veya "2023 güncellemesi" notları) sildik. Mandiant yazılarının özgün tarihi yalnızca görünür yazar satırında yer alıyor. Mandiant akışı araç ve kırmızı takım yazıları da içerdiği için bunları başlık kurallarıyla dışarıda bıraktık. Parçalar CISA'daki gibi oluşturuldu. Sabit bir seed ile 80 Microsoft ve 80 Mandiant kaynağı (231 ve 207 parça) örneklendi. Tablo I sayıları, tarih aralıklarını ve uzunlukları veriyor. Bu metinler ana eğitim kümelerinde hiç yer almıyor. Genişletilmiş bir deney bir yayıncıyı eğitime ekleyip diğerinde test ediyor (Bölüm V). Sayfalar telifli olduğu için repoda yalnızca URL'leri ve parça özetleri (hash) tutuluyor. Toplama betiği metni yeniden oluşturuyor.

B. Çok ajanlı üretim

Şekil 1 hattı özetliyor. Her ajan, bir modele bağlanmış bir rol promptundan ibaret. Bir mesaj alıyor ve bir mesaj döndürüyor. *Analist* bir insan parçasını okuyor ve içerdiği olguları on anahtarlı bir JSON olarak döndürüyor (aktör, zararlı yazılım, CVE'ler, TTP'ler, hedefler, sektörler, gösterge türleri, zaman çizelgesi, etki, önlemler). Parçanın söz etmediği anahtarı boş bırakması isteniyor. Her parça için bir kez, yerel Llama 3.1 8B üzerinde JSON kısıtlı çıktı ve 0.2 sıcaklıkla çalışıyor. Her üretici için bir *Yazar*, olguları ve insan parçasının uzunluğuna eşit bir hedef uzunluğu alıp bir CTI metni yazıyor. Ardından bir *Editör* olguları ve taslağı alıyor ve taslağı, yeni olgu eklememe talimatıyla, olgulara göre düzeltiyor. Yazar

Tablo I
YAYINCIYA GÖRE INSAN YAZIMI CTI. BÜTÜN PARÇALAR 30 KASIM 2022 VEYA ÖNCESINDE YAYIMLANMIŞ BELGELERDEN ALINMIŞTIR.

Yayıncı	Kaynak	Parça	Yayın tarihi	Medyan kelime	IQR kelime	Rol
CISA	203	406	2015-02-20–2022-11-17	302	239–326	Eğitim, doğrulama, test
Microsoft	80	231	2012-01-16–2022-11-22	319	298–334	Bağımsız test
Mandiant	80	207	2010-08-16–2022-11-28	306	280–322	Bağımsız test

promptu dört şablondan biri (SOC bülteni, güvenlik firması blogu, devlet bildirimi, olay müdahale raporu), örnekleme sıcaklığı 0.7 veya 1.0. İkisi de üretici ve parçayla tohumlanan bir rastgele sayı üretecinden çekiliyor. Böylece yarıda kalan bir çalıştırma aynı seçimlerle sürüyor. Seçimler, bütün ajan mesajları ve model adıyla birlikte her metinle saklanıyor. Boş gelen ya da ret cümlesiyle başlayan bir cevap en çok üç kez yeniden isteniyor. Sonra parça o üretici için atlanıyor.

Eğitim üreticileri Ollama ile yerelde çalışıyor: A, Llama 3.1 8B (Meta); B, Qwen 2.5 7B (Alibaba); C, Mistral 7B (Mistral AI). Daha büyük iki API modeli yalnızca görülmemiş test üreticisi olarak kullanılıyor: D, gpt-oss-120b (OpenAI ağırlıkları, Groq API) ve E, Gemini 3.1 Flash-Lite (Google API). Ücretsiz katmanları günde yaklaşık 200 bin token ve 500 istek veriyor. Bu yüzden kısıtsız bir ilk çalıştırmadan sonra D ve E'yi, kaynağı en az bir seed'in test kümesine düşen parçalarla ve çok ajanlı koşulla sınırladık. Bu 191 parçanın hepsinin D ve E sürümü var. Kısıtlamadan önce üretilmiş metinlerle birlikte kapsam, bütün parçaların 61% ve 75% kadarına çıkıyor. Bu fazladan metinler eğitimde hiç kullanılmıyor, yalnızca derlem istatistiklerine giriyor. Kaynakların sabit bir 20% kadarı için her yerel üretici bir de *tek ajan* sürümü yazıyor: insan parçasını okuyup tek çağrıda yeniden yazan bir ajan. Dış yayıncıların parçaları da aynı hatla A, B ve C'den LLM sürümleri alıyor.

C. Yeniden yazım, prompt stratejileri ve kısmi üretim

Kaynağı en az bir seed'in test kümesinde bulunan her parça için A, B ve C'nin çok ajanlı metinlerinden yeni LLM metinleri türettik (Tablo VI bunları listeliyor). Beş koşul bitmiş bir metni yeniden yazıyor: *aynı modelle yeniden ifade* (üretici kendi metnini her olguyu, adı ve sayıyı koruma talimatıyla yeniden yazıyor), *başka modelle yeniden ifade* (A'nın metnini B, B'ninkini C, C'ninkini A yeniden yazıyor), *iki kez yeniden ifade* (aynı modelle yapılan yeniden ifadenin bir kez daha yeniden ifade edilmesi), Almanca üzerinden *geri çeviri* ve ulusal bir CERT'te çalışan deneyimli bir analistin dilini, birinci şahıs ve okura tavsiye olmadan isteyen bir *"insanlaştır"* promptu. İki prompt stratejisi Yazar'ı değiştiriyor: bir devlet bildiriminin kişisiz dilini isteyen *bildiri üslubu* promptu ve hiçbir seed'in test kümesinde bulunmayan kaynaklardan alınmış iki insan parçası gösteren *az örnekli* prompt. *Yalnızca Yazar* koşulu, taslağın Editör'den önceki hâli. Üçüncü ajanın neyi değiştirdiğini ölçüyor. Son olarak *kısmen üretilmiş* metinler, bir insan parçasının cümleleriyle onun LLM sürümünün cümlelerini, LLM cümleleri kelimelerin yaklaşık %25'ini, %50'sini veya %75'ini oluşturacak biçimde birleştiriyor. RoBERTa yalnızca ilk 256 tokenı okuduğu için LLM bloğu rastgele başa veya sona yerleştiriliyor. Toplamda bu adım 6293 LLM metni ekliyor. Kısmen üretilmiş her metni LLM olarak etiketliyoruz. Bu bir kabul: kelimelerinin dörtte biri LLM'den gelen bir metin çoğunlukla insan metni ve bu metinlerdeki "duyarlılık", bir dedektörün tepki vermesi için araya ne kadar LLM metni girmesi gerektiğini ölçüyor.

İnsanların LLM taslaklarını düzelttiği, insan tarafından düzenlenmiş bir küme oluşturmadık. Bu tür düzenlemeleri başka bir LLM ile taklit etmek LLM yeniden yazımını ikinci kez ölçmek olurdu. Bu koşulu sonraki çalışmaya bırakıyor ve en yakın vekil olarak cümle düzeyindeki karışımları kullanıyoruz (Bölüm VIII).

D. Ön işleme ve bölme

LLM çıktıları metnin parçası olmayan ambalajlar içeriyor: akıl yürütme etiketleri, "Here is the revised text" gibi girişler, başlıklar, markdown, madde işaretleri ve kelime sayısı notları. Bunları siliyor ve insan ya da üretilmiş, bütün metinlerde tire ve tırnakların Unicode varyantlarını normalleştiriyoruz. Bu adımın etkisi bir ablasyonda ölçülüyor. 50 kelimeden kısa metinler atılıyor.

Bölme kaynak rapor düzeyinde yapılıyor: CISA kaynaklarının %70'i eğitim, %10'u doğrulama ve %20'si test için, her seed (42, 123, 2024) için ayrı. Bir insan parçası ve yeniden yazılmış olsun olmasın bütün LLM sürümleri her zaman aynı kümeye düşüyor. Vektörleştiriciler, ölçekleyiciler, dedektörler, Koordinatör, kalibratörler ve eşikler yalnızca eğitim veya doğrulama verisiyle kuruluyor. Test, D, E, yeniden yazılmış ve dış yayıncı metinleri yalnızca puanlanıyor.

IV. TESPIT AJANLARI

A. Üyeler

- **Lexical-LR** (baseline 1): kelime 1–2-gram ve karakter 3–5-gram TF-IDF ile lojistik regresyon.
- **Lexical-SVM** (baseline 2): aynı özelliklerle doğrusal SVM, Platt kalibrasyonlu.
- **Stilometri**: beş grupta 32 özellik (uzunluk, MTLD dahil sözcük çeşitliliği [29], noktalama, tekrar, sözcük türü oranları) ile XGBoost.
- **Transformer**: üç epoch ince ayar yapılmış RoBERTa-base [13], en fazla 256 token.
- **LLM Yargıç**: üretimde kullanılmayan bir aileden Gemma 2 9B; bir metnin yapay zekâ tarafından üretilmiş olma olasılığı sıfır örnekli olarak soruluyor.

B. Eğitim gerektirmeyen referans dedektörler

Fast-DetectGPT, koşullu olasılık eğriliğinin analitik biçimini, örnekleme ve puanlama modeli olarak GPT-Neo 2.7B

ile kullanıyor [10]. *Binoculars*, yazarların model çiftini kullanıyor: gözlemci olarak Falcon-7B, icracı olarak Falcon-7B-Instruct [11]. İki 7B model 8 GB'lık bir GPU'ya birlikte sığmadığı için ikisi de 4 bit hassasiyetle yükleniyor ve iki geçişte çalıştırılıyor. Gözlemcinin sonraki token dağılımı en olası 64 tokena kırpılıp yeniden normalleştirilerek diske yazılıyor, icracı geçişi şaşkınlığı ve çapraz şaşkınlığı bu dağılımdan hesaplıyor. Kırpma olmadan bu iki geçişli hesap tam skoru yeniden üretiyor. Bunu küçük bir modelde kontrol ettik. Kırpma ise zararsız değil. Her iki yolla puanlanan 16 rastgele metnin 16 tanesinde kırpılmış skor tam skordan yüksek çıktı. Mutlak farkın medyanı 1.5×10^{-1}, tam skorların medyanı 0.930, iki skor arasındaki sıra korelasyonu ise 0.944 oldu. Yani Binoculars skorlarımız kaymış durumda, ama metinleri tam skorlarla neredeyse aynı sıraya diziyor. İki yöntem de en çok 512 token okuyor. Eğitim gerektirmiyorlar ama skorları olasılık değil. Denetimli dedektörlerle aynı eşik kuralları altında karşılaştırılabilmeleri için bu skorları her eğitim kümesinin doğrulama kısmında, sınıf dengeli Platt ölçeklemeyle olasılığa çeviriyoruz.

C. Koordinatör

Koordinatör, beş üyenin olasılıklarının logitleri üzerinde bir lojistik regresyon (yığınlanmış genelleme [20]):

$$P(\text{LLM} \mid x) = \sigma\Big(b + \sum_{m=1}^{5} w_m \log \frac{p_m(x)}{1 - p_m(x)}\Big). \qquad (1)$$

Burada $p_m(x)$, m üyesinin verdiği olasılık, σ lojistik fonksiyon. w_m ağırlıkları ve b sabiti, eğitim üreticilerinin doğrulama kümesiyle, yani üyelerin eğitilmediği veriyle kuruluyor. Ağırlıklar her çalıştırmada kaydediliyor ve sonuçlarla birlikte veriliyor. Bir yığının neden en iyi üyesinin gerisinde kalabildiğini bulmak için aynı tahminler üzerinde dört çeşit değerlendiriyoruz: üye logitlerinin ağırlıksız ortalaması (öğrenilmiş ağırlık yok), doğrulama F1 değeri en yüksek tek üye (birleştirme yerine seçme), eğitim kümesinde *bulunmayan* yerel üreticilerin doğrulama metinleriyle kurulan bir yığın (ağırlıklar benzetilmiş bir üretici kayması altında öğreniliyor) ve iki sıfır örnekli dedektörün üye olarak eklendiği yığın.

D. Neden birden çok ajan

Üretim. Olgu çıkarmayı yazımdan ayırmak deneyin işine yarıyor. Tek ajan koşulumuzdaki gibi tek bir prompt insan parçasını okuyup yeniden yazdığında çıktı kaynağın adlarını ve ifadelerini koruyor, üstelik farklı üreticiler bunların farklı miktarını koruyor. Tek ajanlı bir metnin kelime üçlülerinin, üreticiye göre 0.237 ile 0.359 arasındaki bir kısmı kendi insan parçasında da geçiyor. Aynı parçaların çok ajanlı metinlerinde bu oran 0.091 ile 0.145 arasında. Kalan örtüşme, olgular üzerinden geçen varlık adlarından ve kalıp ifadelerden geliyor. Tek ajan koşulunda üreticiler arası farklar bu yüzden üslup ile kopyalamayı karıştırırdı. Ortak bir Analist ile içerik beş üreticide de sabit kalıyor ve insan ifadesi Yazar'a hiç gösterilmiyor. Editör, insan CTI üretimindeki gibi bir gözden geçirme adımı ekliyor. Etkisi yalnızca Yazar koşuluyla ölçülüyor. Bedeli metin başına bir yerine üç çağrı.

Tespit. Üyeler farklı kanıtlar kullanıyor: yüzeydeki n-gram'lar, üslubun dağılımsal istatistikleri, bağlamsal temsiller, talimatla eğitilmiş bir modelin yargısı ve referans dedektörler için başka bir dil modeli altındaki olabilirlik. Bir üretici kayması bunları eşit etkilemiyor. Daha büyük bir üretici insan uzunluğunu tutturup bir stilometrik ipucunu ortadan kaldırırken, sözcüksel modellerin kullandığı düşük özel ad oranını koruyabilir. Üye hataları tam ilişkili değilse öğrenilmiş bir birleşim her üyeden daha doğru olabilir. Aynı gerekçe birleşimin nerede başarısız olacağını da söylüyor. Eğitim üreticilerinin doğrulama metinleriyle kurulan ağırlıklar orada en güvenilir olan üyeyi ödüllendiriyor. Bu üye, yeni koşula en iyi taşınan üye olmak zorunda değil. Yukarıdaki çeşitler bunu doğrudan sınıyor; Bölüm VI birleşimin ne zaman yardımcı olduğunu ve ne zaman olmadığını veriyor.

V. Deney Düzeni

A. Senaryolar

Yerel üreticilerin boş olmayan her alt kümesi (A, B, C, AB, AC, BC, ABC) ve her seed için bir eğitim yapılıyor ve eğitilen her model her üreticinin test kümesinde deneniyor. Aynı eğitimlerden dört düzen çıkıyor: *E1 aynı üretici* (aynı üreticiyle eğitim ve test, ayrıca birleşik ABC modeli), *E2 üreticiler arası* (birinde eğitim, diğerinde test; ödevde istenen İnsan+A $\rightarrow$ İnsan+B ve İnsan+A $\rightarrow$ İnsan+C durumları bunun içinde), *E3 birini dışarıda bırak* (ikisinde eğitim, üçüncüsünde test) ve *E4 dış üretici* (herhangi bir eğitim kümesi, D veya E ile test). Her test kümesi bir üreticinin test kaynaklarına ait LLM metinlerini ve bunların üretildiği insan parçalarını içeriyor. Sınıflar bu yüzden dengeli.

Aynı eğitimler dış yayıncıları ve yeniden yazılmış metinleri de puanlıyor. *Yayıncı kayması*, Microsoft ve Mandiant'ın bütün insan parçalarındaki yanlış pozitif oranıyla ve bu parçaların A, B ve C sürümleriyle eşleştirildiği kümede duyarlılık, F1 ve ROC-AUC ile ölçülüyor. *Yeniden yazım ve kısmi üretim*, türetilmiş metinlerdeki duyarlılıkla ölçülüyor ve aynı parçaların çok ajanlı metinlerindeki duyarlılıkla karşılaştırılıyor. Tek ajan koşulu aynı modelin aynı parçalara ait çok ajanlı metinleriyle karşılaştırılıyor. Her biri üç seed ile yapılan iki genişletilmiş eğitim, daha çeşitli eğitim verisinin yardımcı olup olmadığını sınıyor: ABC artı bir dış yayıncı (insan ve LLM sürümleri) ile eğitip diğer yayıncıda test, ve ABC artı eğitim kaynaklarının yeniden ifade edilmiş ve tek ajanlı metinleri.

B. Metrikler ve istatistik

Doğruluk, kesinlik, duyarlılık, F1, makro-F1, ROC-AUC ve PR-AUC değerlerini üç seed üzerinden ortalama $\pm$ standart sapma olarak veriyoruz. Aralıklar ve testler kaynak rapor düzeyinde çalışıyor. Test kaynakları yerine koyarak yeniden örnekleniyor (2.000 bootstrap örneği). Bu, bir metrik için %95 yüzdelik aralığı veriyor. Bir karşılaştırmada metrik farkı iki sistem için aynı yeniden örneklenmiş kaynaklar üzerinde hesaplanıyor. Bu da eşleştirilmiş bir aralık ve çift yönlü bir p değeri veriyor. 2.000 örnekle böyle bir p değeri en az $2/2001$ olabiliyor. Dolayısıyla Holm düzeltmesi [30] elliden fazla testlik bir ailede hiçbir şeyi reddedemiyor. Bu yüzden bir karşılaştırmanın çalıştırmalarını testten önce havuzluyoruz:

aynı üretici ile başka üretici arasındaki fark için dedektör ve hedef başına bir test, Koordinatör ile RoBERTa için senaryo başına bir test, yeniden yazım koşulları için koşul ve dedektör başına bir test. Holm yöntemi bu ailelerin her birinin içinde uygulanıyor. Testlerin çalıştırma veya özellik başına verildiği yerlerde Benjamini-Hochberg yöntemi [31] kullanılıyor. Dedektörler tek tek test kümelerinde kesin McNemar testiyle de karşılaştırılıyor. Düzeltme dedektör çifti başına Holm ile. Dilsel farklar Mann-Whitney U testi ve etki büyüklüğü olarak Cliff δ ile sınanıyor. Ayırt edici n-gram'lar ağırlıklı log-odds ile sıralanıyor [32].

C. Kalibrasyon ve eşikler

Her dedektör ve eğitim için doğrulama kümesinde üç kalibratör kuruyoruz: Platt ölçekleme (skorun logiti üzerinde lojistik regresyon) [25], sıcaklık ölçekleme (doğrulama log-kaybıyla seçilen tek bir logit böleni) [24] ve izotonik regresyon [26]. Koordinatör de doğrulama kümesinde kurulduğu için kalibratörleri, kaynağa göre gruplanmış beş katlı bir bölmeden gelen kat dışı yığın skorlarını kullanıyor. Olasılık kalitesi test kümelerinde Brier skoru, 15 eşit genişlikte kutulu beklenen kalibrasyon hatası [28] ve negatif log-olabilirlik ile ölçülüyor ve güvenilirlik diyagramlarıyla gösteriliyor (Şekil 7).

Hepsi doğrulama verisinde belirlenen beş karar kuralı karşılaştırılıyor: sabit 0.5 eşiği; doğrulama F1 değerini en yükseğe çıkaran eşik; ne eğitim kümesinde ne de test üreticisi olan yerel üreticilerin doğrulama metinlerinde F1'i en yükseğe çıkaran *sözde görülmemiş* eşik; ve iki *insan yüzdeliği* eşiği. Bunlar doğrulama insan skorlarının 99. ve 95. yüzdelikleri; %1 veya %5 yanlış pozitif oranını hedefliyor ve hiç LLM metni kullanmıyorlar. Son iki kural test sırasında karşılaşılacak üretici hakkında hiçbir şey varsaymıyor. Varsaydıkları şey, test sırasındaki insan metninin CISA doğrulama metni gibi skor alacağı; dış yayıncılar bu varsayımı sınıyor.

D. Maliyet

Çıkarım süresi tek bir dizüstü RTX 4060 (8 GB) üzerinde, sabit bir test metni örneğinde, üç tekrarla ve GPU'da başka bir şey çalışmazken ölçülüyor. LLM yargıç daha küçük bir örnekte ölçülüyor. Eğitim süresi her çalıştırmada kaydediliyor. Koordinatör'ün maliyeti, üyelerinin art arda çalıştırılmasının toplamı.

E. Hata analizi

Yanlış negatifler (insan olarak puanlanan LLM metinleri), tek bir yerel üreticiyle eğitilen modellerden, bütün seed'ler üzerinden alınıyor. Çünkü D bu modellerde kaçıyor. Yanlış pozitifler (LLM olarak puanlanan insan metinleri) CISA için aynı modellerden, firma parçaları için ise birleşik ABC modellerinden alınıyor. Çünkü yanlış alarmlar orada ortaya çıkıyor. Her metin için uzunluğu, MTLD'yi, tür-örnek oranını, özel ad ve zamir oranlarını, birinci şahıs zamirlerini (*we, our, us, ours*), kurum adlarını, tavsiye bildiren sözcükleri, Analist olgularında bulunmayan teknik tanımlayıcıları (dosya adları, CVE numaraları, adresler, ATT&CK kimlikleri) ve *ipucu* oranını hesaplıyoruz. İpucu oranı, A ile eğitilen Lexical-LR'de en büyük pozitif ağırlığı alan 30 ve en büyük negatif ağırlığı alan 30 terim arasındaki kelime n-gram'larının (sırasıyla 23 ve 20 tane) 100 kelimedeki geçiş sayısı.

Bu özelliklerle üç analiz yapıyoruz. Birincisinde her hata, uyan ilk kurala göre tek bir kategoriye atanıyor ve her kategorinin hatalar içindeki payı, aynı gruptaki bütün metinler içindeki payının yanında veriliyor. İkinci sayı olmadan, yalnızca üreticiyi betimleyen bir kategori bir neden gibi görünürdü. İkincisinde yanlış sınıflandırılan metinler doğru sınıflandırılanlarla özellik özellik karşılaştırılıyor (Mann-Whitney U, Cliff δ, Benjamini-Hochberg). Her çalıştırmada kaçan bir metin dokuz kez sayılmasın diye önce her metnin çalıştırmalar üzerinden ortalaması alınıyor. Üçüncüsünde hata göstergesinin standartlaştırılmış özellikler üzerindeki, standart hataları kaynağa göre kümelenmiş lojistik regresyonu, diğerleri sabitken hangi özelliklerin hata olasılık oranını değiştirdiğini kestiriyor. Kuralları tek bir yazar tanımladı. İkinci bir işaretleyiciyle doğrulanmadılar.

VI. Sonuçlar

A. Dilsel farklar

Tablo II ve Şekil 2 derlemi özetliyor. 160 üretici-özellik karşılaştırmasının 61 tanesinde, Benjamini-Hochberg düzeltmesinden sonra da büyük bir etki ($|\delta| \geq 0.474$) kalıyor. En tutarlı fark sözcük çeşitliliğinde. Medyan MTLD, CISA parçalarında 84. Üreticilerde 90 ile 199 arasında. Hapax oranı her üreticide insandan yüksek (δ 0.603 ile 0.932 arası). LLM metinleri daha az bigram tekrarlıyor ve daha az özel ad kullanıyor. İnsan parçaları kurumları, ürünleri, dosyaları ve tarihleri tekrar tekrar adıyla anıyor. Üreticiler aynı olguları genel ifadelerle aktarıyor. Yerel üreticiler ayrıca kısa yazıyor (medyan 163, 147 ve 214 kelime; insanda 302), D ve E ise insan uzunluğunu tutturuyor (306 ve 300). Log-odds sıralaması da aynı yönü gösteriyor. LLM metinleri *our*, *we*, *potential*, *to mitigate* ve *defenders should* gibi okura tavsiye veren ifadeleri sık kullanıyor. CISA parçalarında ise atıf ve çapraz gönderme bildiren *CISA*, *FBI*, *see* ve *note* sık geçiyor. Tek tek özellikler düzeyinde H1 beş üreticinin hepsinde geçerli.

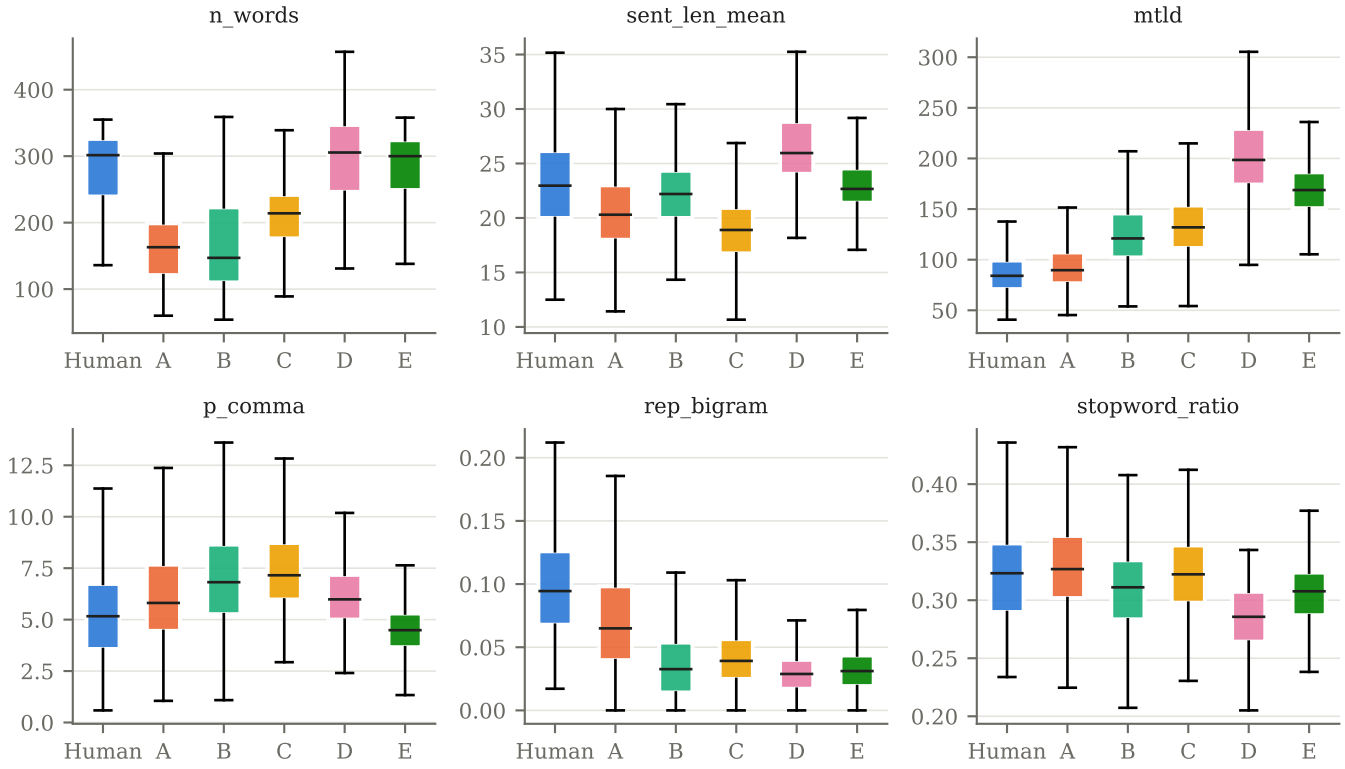
İki firma yayıncısı bu özelliklerin bir kısmında CISA ile üreticilerin arasında kalıyor. Microsoft ve Mandiant parçaları CISA'ya göre daha çok zamir ($\delta = 0.785$ ve 0.648), daha az özel ad ($\delta = -0.595$ ve -0.430) kullanıyor; LLM metni de CISA'dan bu yönde ayrılıyor. 64 yayıncı-özellik karşılaştırmasının 11 tanesinde etki büyük.

B. Aynı üretici ve üreticiler arası tespit

Tek bir üreticiyle eğitilen modellerin ana sonucu Tablo III'de. Aynı üreticide tespit neredeyse kusursuz: F1, sözcüksel baseline'larda 0.997, RoBERTa'da 0.992, Koordinatör'de 0.998. Başka bir yerel üreticiye geçmek az kaybettiriyor (Lexical-LR 0.966, RoBERTa 0.990). İki üreticiyle eğitilip üçüncüsünde sınanan modellerde de sonuç benzer (Lexical-LR 0.997, RoBERTa 0.984). Bu dedektörler Gemini (E) metinlerini de neredeyse aynı başarıyla buluyor. Büyük düşüş gpt-oss-120b'de (D). Lexical-LR'nin F1 değeri 0.329 (%95 GA [0.288, 0.367]), Lexical-SVM'inki 0.327;

Tablo II
KAYNAĞA GÖRE DERLEM. MEDYANLAR ÇOK AJANLI METİNLER ÜZERİNDEN (İLK SATIRDA İNSAN PARÇALARI).

Kaynak	Çok ajan	Tek ajan	Kelime	MTLD	Tekrar bigram	PROPN
İnsan (CISA)	406	0	302	84	0.094	0.114
A: Llama 3.1 8B	406	83	163	90	0.065	0.050
B: Qwen 2.5 7B	405	83	147	121	0.033	0.055
C: Mistral 7B	406	83	214	132	0.039	0.059
D: gpt-oss-120b	248	0	306	199	0.029	0.049
E: Gemini 3.1 Flash-Lite	305	0	300	169	0.031	0.033



Şekil 2. CISA parçaları ve beş üretici (çok ajanlı metinler) için seçilmiş stilometrik özellikler.

RoBERTa 0.859 ([0.834, 0.880]), Koordinatör 0.721 ([0.689, 0.751]) ile tutunuyor. Bütün eğitim kümeleri Şekil 3'te.

Lexical-LR, D metinlerini hâlâ insan metinlerinin üstüne sıralıyor (AUC 0.979), ama sabit eşikte bunların ancak 0.208 kadarını yakalıyor. Şekil 4'de D skorları insan parçalarıyla yerel üreticiler arasında ayrı bir bant oluşturuyor ve çoğu 0.5'in altında kalıyor. Daha düşük bir eşik bunları insan metinlerinden ayırabilirdi. Daha çok üreticiyle eğitim sınırı kaydırıyor. İki üreticiyle Lexical-LR'nin D'deki F1 değeri 0.764, üçüyle 0.883 oluyor. Üç üreticiyle RoBERTa 0.958, Koordinatör 0.915 değerine ulaşıyor.

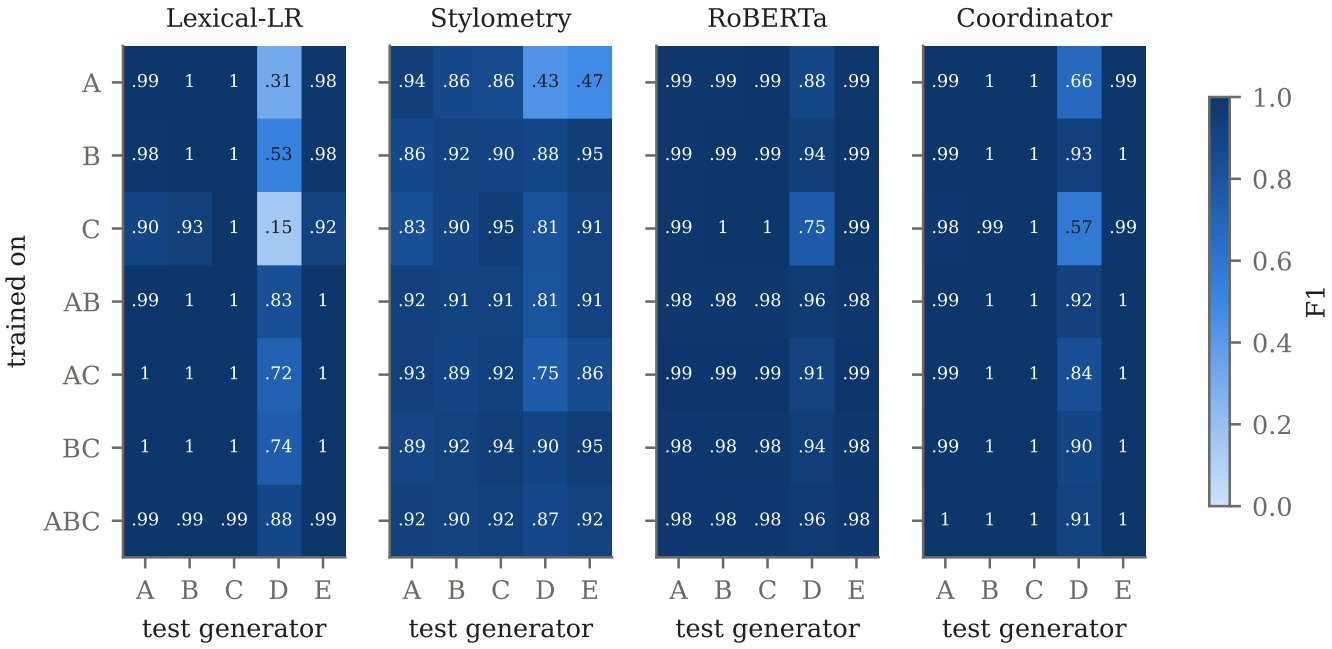
Eğitim gerektirmeyen iki dedektör, aynı üreticide bile denetimli dedektörlerin çok gerisinde (AUC: Fast-DetectGPT 0.828, Binoculars 0.900). Büyük üreticilerde sıralamaları daha da bozuluyor (D'de 0.699 ve 0.734, E'de 0.613 ve 0.671). LLM Yargıç şans düzeyine yakın (F1 0.504). Aynı üreticideki AUC değeri (0.409) 0.5'in altında, çünkü CISA test parçalarının 82% kadarını yapay zekâ yazımı sayıyor. Bu oran bazı üreticilerin metinlerindekinden yüksek.

Çalıştırmalar havuzlandığında, eğitim üreticisinden başka bir yerel üreticiye geçişte kaybedilen F1, Lexical-LR'de 0.030 (%95 GA [0.023, 0.038]), RoBERTa'da 0.002 ([0.000, 0.005]). Holm düzeltmesinden sonra kayıp, eğitilmiş ve eğitimsiz 7 dedektörün 5 tanesinde anlamlı. İstisnalar RoBERTa ve Binoculars. D'de kayıp Lexical-LR'de 0.667, RoBERTa'da 0.134, Koordinatör'de 0.277 ve 7 dedektörün hepsinde anlamlı. E'de 7 dedektörün 5 tanesinde anlamlı; RoBERTa ve Koordinatör ölçülebilir bir kayıp vermiyor. Çalıştırma çalıştırma sınandığında, Benjamini-Hochberg düzeltmesinden sonra 126 yerel karşılaştırmanın 37 tanesi, D ve E'deki 126 karşılaştırmanın 86 tanesi anlamlı kalıyor. Tek tek test kümelerindeki kesin McNemar testleri de bu tabloyla uyumlu. Holm düzeltmesinden sonra RoBERTa 105 test kümesinin 20 tanesinde Lexical-LR'den, Koordinatör 17 tanesinde Lexical-LR'den, 5 tanesinde RoBERTa'dan farklı.

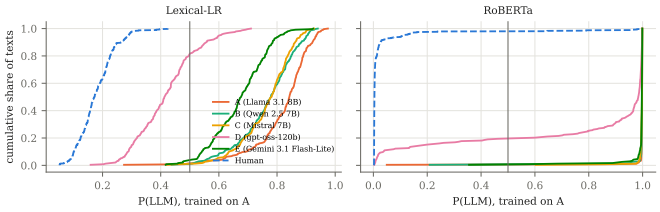
Ödevde istenen düzenin, İnsan + A ile eğitimin bütün metrikleri Tablo IV'de; Koordinatör'ün seed 42 için karmaşıklık matrisleri Şekil 5'de. Koordinatör A'da 1 yanlış pozitif ve 0

Tablo III
TEK BIR ÜRETICIYLE (A, B VEYA C) EĞITILEN MODELLER. F1, EĞITIM ÜRETICILERI ORTALAMASININ ÜÇ SEED ÜZERINDEN ORTALAMA ± STANDART SAPMASIDIR; AUC, ROC-AUC'DIR.

Dedektör	Aynı üretici		Çapraz (A–C)		D: gpt-oss-120b		E: Gemini	
	F1	AUC	F1	AUC	F1	AUC	F1	AUC
Lexical-LR	0.997 ± 0.004	1.000	0.966 ± 0.008	1.000	0.329 ± 0.017	0.979	0.961 ± 0.012	1.000
Lexical-SVM	0.998 ± 0.004	1.000	0.976 ± 0.004	1.000	0.327 ± 0.013	0.983	0.969 ± 0.011	1.000
Stilometri	0.934 ± 0.006	0.984	0.868 ± 0.004	0.959	0.706 ± 0.013	0.878	0.778 ± 0.022	0.931
RoBERTa	0.992 ± 0.003	1.000	0.990 ± 0.002	1.000	0.859 ± 0.022	0.982	0.991 ± 0.003	1.000
LLM Yargıç	0.504 ± 0.024	0.409	0.504 ± 0.024	0.409	0.499 ± 0.026	0.533	0.628 ± 0.015	0.754
Fast-DetectGPT	0.744 ± 0.009	0.828	0.714 ± 0.033	0.828	0.540 ± 0.054	0.699	0.427 ± 0.053	0.613
Binoculars	0.817 ± 0.024	0.900	0.806 ± 0.025	0.900	0.365 ± 0.042	0.734	0.307 ± 0.060	0.671
Koordinatör	0.998 ± 0.000	1.000	0.993 ± 0.003	1.000	0.721 ± 0.083	0.987	0.995 ± 0.003	1.000



Şekil 3. Her eğitim kümesi (satırlar) ve test üreticisi (sütunlar) için F1, üç seed ortalaması. D ve E eğitimde hiç kullanılmıyor.



Şekil 4. A ile eğitilen modellerde P(LLM) değerinin birikimli dağılımı. İnsan parçaları (kesikli çizgi) ve her üreticinin metinleri; dikey çizgi sabit eşik.

yanlış negatif yapıyor (TP 74, TN 73). D'de yanlış pozitif sayısı yine 1, ama 74 LLM metninin 44 tanesi kaçıyor. Bir CTI hattında pahalı olan hata yanlış negatif. Kaçırılan sahte rapor bilgi tabanına giriyor ve istihbarat diye paylaşılıyor. Yanlış pozitifin bedeli ise bir analistin metne ikinci kez bakması.

C. Yayıncı kayması

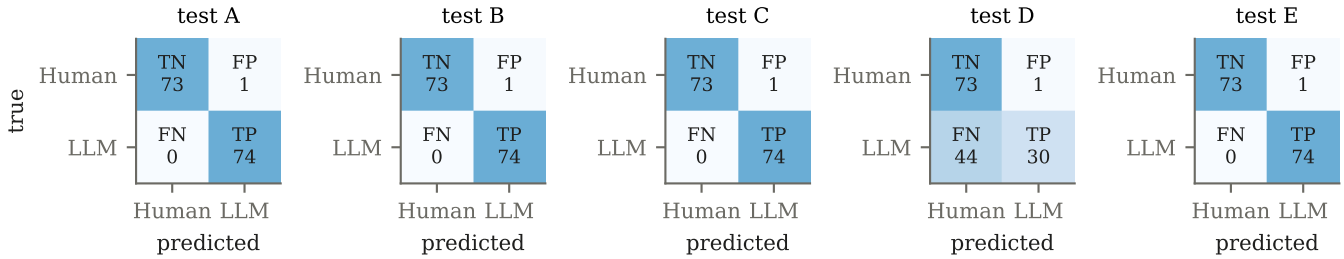
D ile en iyi başa çıkan modeller firma yazılarında yanlış alarm veriyor (Tablo V). CISA ve üç yerel üreticiyle eğitilen Lexical-LR, Microsoft parçalarının 0.152, Mandiant parçalarının 0.137 kadarını LLM yazımı diye işaretliyor; CISA test parçalarında bu oran 0.014. RoBERTa'da oranlar 0.159 ve 0.198, CISA'da 0.042. Koordinatör daha az yanılıyor (0.046 ve 0.064). Firma parçaları kendi LLM sürümleriyle eşleştirildiğinde üç modelin AUC değeri de 1.000. Firma insan metinleri eşiğin üstünde ama kendi LLM sürümlerinin altında skor alıyor.

Yanlış alarmlar eğitimdeki üretici sayısıyla artıyor. Tek üreticiyle eğitilen Lexical-LR Microsoft parçalarının 0.003, Mandiant parçalarının 0.003 kadarını işaretliyor. İki üreticiyle bu oranlar 0.041 ve 0.053, üç üreticiyle yukarıdaki değerler oluyor. RoBERTa 0.075 ve 0.093 değerlerinden iki üreticiyle 0.140 ve 0.159 değerlerine çıkıyor. Demek ki önceki alt bölümde D'yi geri kazandıran havuzlama, firma metinlerindeki yanlış alarmları üreten adımın ta kendisi. LLM metninin üç ayrı yazılış biçimini görmüş bir model "LLM" bölgesini daha geniş çiziyor ve CISA'ya benzemeyen insan metni bu bölgeye düşüyor.

Firma yayıncılarından birini eğitime eklemek, diğerin-

Tablo IV
İNSAN + A ILE EĞITIM, İNSAN + HER ÜRETICI ILE TEST (SEED'LER ÜZERINDEN ORTALAMA ± STD).

Test	Dedektör	Doğruluk	Kesinlik	Duyarlılık	F1	Makro-F1	ROC-AUC	PR-AUC
A	Lexical-LR	0.994 ± 0.006	1.000 ± 0.000	0.988 ± 0.013	0.994 ± 0.006	0.994 ± 0.006	1.000 ± 0.000	1.000 ± 0.000
A	RoBERTa	0.987 ± 0.014	0.979 ± 0.027	0.996 ± 0.007	0.987 ± 0.013	0.987 ± 0.014	1.000 ± 0.000	1.000 ± 0.000
A	Koordinatör	0.994 ± 0.000	0.992 ± 0.007	0.996 ± 0.007	0.994 ± 0.000	0.994 ± 0.000	1.000 ± 0.000	1.000 ± 0.000
B	Lexical-LR	0.996 ± 0.004	1.000 ± 0.000	0.991 ± 0.008	0.996 ± 0.004	0.996 ± 0.004	1.000 ± 0.000	1.000 ± 0.000
B	RoBERTa	0.987 ± 0.012	0.979 ± 0.027	0.996 ± 0.007	0.987 ± 0.012	0.987 ± 0.012	1.000 ± 0.001	1.000 ± 0.001
B	Koordinatör	0.996 ± 0.004	0.992 ± 0.007	1.000 ± 0.000	0.996 ± 0.004	0.996 ± 0.004	1.000 ± 0.000	1.000 ± 0.000
C	Lexical-LR	0.996 ± 0.004	1.000 ± 0.000	0.991 ± 0.008	0.996 ± 0.004	0.996 ± 0.004	1.000 ± 0.000	1.000 ± 0.000
C	RoBERTa	0.989 ± 0.014	0.979 ± 0.027	1.000 ± 0.000	0.989 ± 0.014	0.989 ± 0.014	1.000 ± 0.001	1.000 ± 0.001
C	Koordinatör	0.996 ± 0.004	0.992 ± 0.007	1.000 ± 0.000	0.996 ± 0.004	0.996 ± 0.004	1.000 ± 0.000	1.000 ± 0.000
D	Lexical-LR	0.593 ± 0.004	1.000 ± 0.000	0.185 ± 0.009	0.313 ± 0.012	0.512 ± 0.007	0.980 ± 0.018	0.980 ± 0.019
D	RoBERTa	0.894 ± 0.065	0.977 ± 0.029	0.810 ± 0.149	0.879 ± 0.087	0.892 ± 0.069	0.977 ± 0.017	0.977 ± 0.018
D	Koordinatör	0.747 ± 0.047	0.983 ± 0.016	0.503 ± 0.093	0.662 ± 0.084	0.730 ± 0.057	0.972 ± 0.014	0.972 ± 0.016
E	Lexical-LR	0.981 ± 0.001	1.000 ± 0.000	0.962 ± 0.002	0.981 ± 0.001	0.981 ± 0.001	1.000 ± 0.000	1.000 ± 0.000
E	RoBERTa	0.987 ± 0.012	0.979 ± 0.027	0.996 ± 0.007	0.987 ± 0.012	0.987 ± 0.012	1.000 ± 0.001	1.000 ± 0.001
E	Koordinatör	0.994 ± 0.000	0.992 ± 0.007	0.996 ± 0.007	0.994 ± 0.000	0.994 ± 0.000	1.000 ± 0.000	1.000 ± 0.000



Şekil 5. İnsan + A ile eğitilen Koordinatör (seed 42), her üreticide test.

Tablo V
CISA + ABC ILE EĞITILEN MODELLER, EŞIK 0.5. FPR YAYINCININ BÜTÜN INSAN PARÇALARI ÜZERINDE; DUYARLILIK, F1 VE AUC INSAN PARÇALARI ILE BUNLARIN A, B VE C SÜRÜMLERI ÜZERINDE, ORTALAMA. FPR VE F1 ÜÇ SEED ÜZERINDEN ORTALAMA ± STD; ARALIK KAYNAKLARI YENIDEN ÖRNEKLER. SON SÜTUNDA DIĞER DIŞ YAYINCI EĞITIME EKLENMIŞTIR.

Yayıncı	Dedektör	FPR	%95 GA	Duyarlılık	F1	ROC-AUC	FPR, diğer yayıncı eğitimde
CISA	Lexical-LR	0.014±0.023	–	0.999	0.993±0.011	1.000	–
CISA	RoBERTa	0.042±0.007	–	1.000	0.979±0.003	1.000	–
CISA	Koordinatör	0.009±0.007	–	1.000	0.996±0.004	1.000	–
CISA	Fast-DetectGPT	0.222±0.048	–	0.721	0.739±0.029	0.828	–
CISA	Binoculars	0.093±0.008	–	0.750	0.811±0.031	0.900	–
Microsoft	Lexical-LR	0.152±0.009	[0.126, 0.177]	1.000	0.930±0.004	1.000	0.016±0.007
Microsoft	RoBERTa	0.159±0.029	[0.134, 0.184]	1.000	0.927±0.012	1.000	0.022±0.004
Microsoft	Koordinatör	0.046±0.046	[0.033, 0.061]	1.000	0.978±0.022	1.000	0.000±0.000
Microsoft	Fast-DetectGPT	0.110±0.025	[0.086, 0.134]	0.874	0.880±0.008	0.954	–
Microsoft	Binoculars	0.030±0.007	[0.017, 0.045]	0.885	0.924±0.008	0.979	–
Mandiant	Lexical-LR	0.137±0.012	[0.111, 0.166]	1.000	0.936±0.005	1.000	0.011±0.003
Mandiant	RoBERTa	0.198±0.041	[0.162, 0.237]	1.000	0.910±0.017	1.000	0.052±0.023
Mandiant	Koordinatör	0.064±0.016	[0.045, 0.086]	1.000	0.969±0.007	1.000	0.023±0.007
Mandiant	Fast-DetectGPT	0.116±0.017	[0.086, 0.150]	0.825	0.848±0.011	0.940	–
Mandiant	Binoculars	0.016±0.006	[0.003, 0.031]	0.826	0.895±0.008	0.977	–

deki sorunun çoğunu gideriyor. Microsoft'taki yanlış pozitif oranı Lexical-LR'de 0.016, RoBERTa'da 0.022, Koordinatör'de 0.000 oluyor; Mandiant'ta sırasıyla 0.011, 0.052 ve 0.023. Eğitimsiz dedektörlerde durum tersi: firma metinlerinde CISA'dakinden daha az yanılıyorlar (Binoculars CISA'da 0.093, Microsoft'ta 0.030, Mandiant'ta 0.016; Fast-DetectGPT sırasıyla 0.222, 0.110 ve 0.116). Puanlama yapan bir dil modeli CISA üslubunu tanımıyor, dolayısıyla firma yazısı ona olağandışı görünmüyor. Hangi firma parçalarının işaretlendiği Bölüm VI-I'te inceleniyor.

D. Yeniden yazım, prompt stratejisi ve kısmi üretim

Bir LLM metnini bir LLM ile yeniden yazmak, onu eğitilmiş dedektörlerden saklamıyor (Tablo VI). Aynı modelle, başka bir modelle ya da iki kez yeniden ifade, geri çeviri ve "insanlaştır" promptu sonrasında Lexical-LR, RoBERTa ve Koordinatör'ün duyarlılığı 0.992 ya da daha yüksek. Yazar'ın Editör'den geçmemiş taslakları da son metinler kadar iyi yakalanıyor; Editör bu dedektörlerin tepki verdiği şeyi değiştirmiyor. Yazar'a iki insan parçası gösteren az örnekli prompt duyarlılığı biraz düşürüyor (Lexical-LR 0.982, RoBERTa 0.969, Koor-

Tablo VI
YENIDEN YAZIM, PROMPT STRATEJISI VE KISMI ÜRETIM ALTINDA LLM METINLERINDE EŞIK 0.5'TE DUYARLILIK, CISA + ABC ILE EĞITIM (ÜÇ SEED ÜZERINDEN ORTALAMA ± STD). *, AYNI PARÇALARIN DEĞIŞIKLIKTEN ÖNCEKI HÂLINE GÖRE DUYARLILIK DEĞIŞIMININ HOLM DÜZELTMELI $p < 0.05$ OLDUĞUNU GÖSTERIR (DEDEKTÖR BAŞINA).

Koşul	Lexical-LR	RoBERTa	Koordinatör	Fast-DetectGPT	Binoculars
Yalnız Yazar, Editör yok	0.999±0.002	1.000±0.000	1.000±0.000	0.839±0.032*	0.855±0.041*
Yeniden ifade, aynı model	0.999±0.002	1.000±0.000	1.000±0.000	0.572±0.084*	0.548±0.074*
Yeniden ifade, başka model	1.000±0.000	1.000±0.000	1.000±0.000	0.610±0.054*	0.575±0.066*
İki kez yeniden ifade	1.000±0.000	1.000±0.000	1.000±0.000	0.588±0.051*	0.570±0.066*
Geri çeviri	0.999±0.002	0.992±0.001*	0.996±0.005	0.588±0.047*	0.495±0.040*
"İnsanlaştır" promptu	0.999±0.002	1.000±0.000	0.999±0.002	0.644±0.054*	0.668±0.046*
Bildiri üslubu promptu	0.997±0.005	0.998±0.003	1.000±0.000	0.642±0.079*	0.637±0.077*
Az örnekli prompt (insan parçaları)	0.982±0.005*	0.969±0.013*	0.950±0.013*	0.764±0.056*	0.774±0.035
Kaynağı okuyan tek ajan	0.663±0.113*	0.721±0.052*	0.601±0.121*	0.757±0.041	0.650±0.086*
%25 LLM cümlesi	0.303±0.050*	0.366±0.038*	0.171±0.134*	0.442±0.069*	0.258±0.057*
%50 LLM cümlesi	0.844±0.005*	0.620±0.036*	0.535±0.023*	0.600±0.058*	0.481±0.081*
%75 LLM cümlesi	0.976±0.004*	0.847±0.020*	0.843±0.015*	0.681±0.047*	0.637±0.066*

dinatör 0.950). Eğitimsiz dedektörler ise etkileniyor. Yeniden ifade Fast-DetectGPT'nin duyarlılığını 0.721 değerinden 0.572 değerine, Binoculars'ınkini 0.749 değerinden 0.548 değerine düşürüyor. Geri çeviri Binoculars'ı 0.495 düzeyine indiriyor. Genel metinde olabilirliğe dayalı dedektörler için bildirilen de bu [7]. İkisi de Yazar'ın düzeltilmemiş taslaklarını son metinlerden daha iyi yakalıyor (0.839 ve 0.855); Editör geçişi çıktıyı puanlama modeli için daha az öngörülebilir kılıyor.

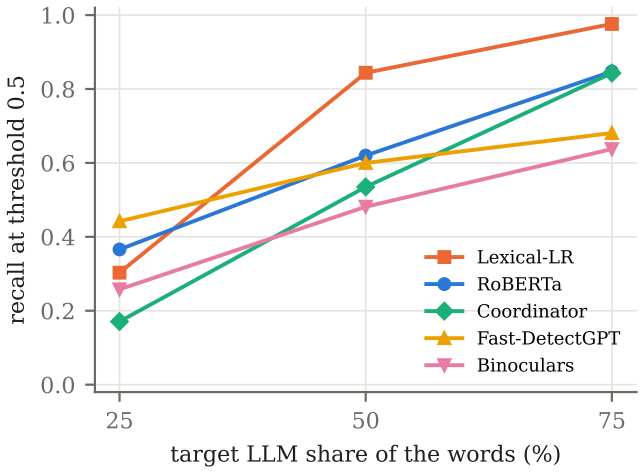
Modelin insan parçasını okuyup yeniden yazdığı tek ajanlı yeniden yazım ise LLM metnini saklıyor. Duyarlılık Lexical-LR'de 0.663, RoBERTa'da 0.721, Koordinatör'de 0.601 düzeyine düşüyor. Aynı modelin aynı parçalara ait çok ajanlı metinlerinde 1.000. Test kümeleri küçük: üç üretici ve üç seed üzerinden 138 tek ajanlı metin var. Bu, Tablo VI'teki standart sapmalarda görülüyor. Kelime üçlülerinin dörtte biri ile üçte biri arasındaki kısmını kaynakla paylaşan metinler bunlar (Bölüm IV-D).

En zor durum kısmen üretilmiş metinler (Şekil 6). Kelimelerin dörtte biri LLM'den geldiğinde duyarlılık 0.303, 0.366 ve 0.171. Yarısı geldiğinde 0.844, 0.620 ve 0.535. RoBERTa'da sonucu LLM bloğunun yeri belirliyor. %50 karışımda LLM bloğuyla başlayan metinlerin 0.947, LLM bloğuyla biten metinlerin 0.269 kadarını buluyor, çünkü yalnızca ilk 256 tokenı okuyor. Metnin tamamını okuyan Lexical-LR'de bu oranlar 0.862 ve 0.826. Koordinatör RoBERTa'yı izliyor (0.817 ve 0.240).

Bu koşullarla eğitim, temel modellerin başarısız olduğu yerde yardımcı oluyor (Tablo VII). Eğitim kaynaklarının yeniden ifade edilmiş ve tek ajanlı metinlerini eklemek, tek ajanlı test metinlerindeki duyarlılığı Lexical-LR'de 0.663 değerinden 0.892 değerine, RoBERTa'da 0.721 değerinden 0.976 değerine çıkarıyor. Hiç D metni eklenmediği hâlde D'deki duyarlılık da 0.801 değerinden 0.969 değerine ve 0.958 değerinden 0.995 değerine yükseliyor. Koordinatör daha az kazanıyor (tek ajanlı metinlerde 0.601 değerinden 0.766 değerine).

E. Kalibrasyon ve karar eşikleri

Aynı üreticide doğrulama verisiyle kalibrasyon olasılıkları iyileştiriyor. Lexical-LR'nin beklenen kalibrasyon hatası ham hâlde 0.167 iken Platt ölçeklemeyle 0.004 oluyor



Şekil 6. CISA + ABC ile eğitilen modellerde, kısmen üretilmiş metinlerde duyarlılığın LLM kelime payına göre değişimi.

(Tablo VIII). Üretici kayması altında ise olasılıklar kötüleşiyor. D'de Lexical-LR'nin negatif log-olabilirliği 0.569 (ham) değerinden 1.823 (Platt) ve 2.037 (izotonik) değerlerine, RoBERTa'nınki 0.384 değerinden 1.772 ve 1.906 değerlerine çıkıyor. Kalibratörler doğrulama verisinden skorların güvenilir olduğunu öğrenip onları keskinleştiriyor; D'de keskinleşen skorlar yanlış (Şekil 7). Bütün skorları ancak birlikte yumuşatıp keskinleştirebilen sıcaklık ölçekleme RoBERTa'ya en az zarar veren yöntem (NLL 0.589). 0.5 eşiğindeki kararlara etkisi ise karışık. Platt ölçekleme Lexical-LR'nin sınırını D'deki F1 değerini 0.329 düzeyinden 0.536 düzeyine çıkaracak kadar kaydırıyor, RoBERTa'nınkini ise 0.859 düzeyinden 0.750 düzeyine indiriyor. Dağılım içi veriyle kalibrasyon karar için güvenilir bir onarım değil, olasılıklar için de güvenli değil.

Eşik, kalibratörden daha önemli (Tablo IX, Şekil 8). Doğrulama F1 değerini en yükseğe çıkaran eşiği seçmek güvenilir bir çözüm değil, çünkü doğrulama metinleri eğitim üreticisinden geliyor. Bu kural Lexical-LR'yi D'de ancak 0.502 düzeyine çıkarıyor, RoBERTa'yı 0.773 düzeyine düşürüyor. Eşiği başka bir yerel üreticide ayarlayan sözde görülmemiş kural, Lexical-LR'nin D'deki F1 değerini 0.329 düzeyinden 0.758 düzeyine

Tablo VII
EŞIK 0.5'TE DUYARLILIK (ÜÇ SEED ÜZERINDEN ORTALAMA ± STD): ABC ILE EĞITIM (TEMEL) VE ABC'YE EĞITIM KAYNAKLARININ TEK AJANLI VE YENIDEN IFADE EDILMIŞ METINLERI EKLENEREK EĞITIM (ART.).

Test	Lexical-LR		RoBERTa		Koordinatör	
	temel	art.	temel	art.	temel	art.
A	0.996±0.007	0.996±0.007	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000
D	0.801±0.018	0.969±0.028	0.958±0.030	0.995±0.008	0.851±0.046	0.866±0.087
E	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000
Yeniden ifade, aynı model	0.999±0.002	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000
İki kez yeniden ifade	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000	1.000±0.000
"İnsanlaştır" promptu	0.999±0.002	1.000±0.000	1.000±0.000	0.999±0.002	0.999±0.002	0.999±0.002
Tek ajan	0.663±0.113	0.892±0.051	0.721±0.052	0.976±0.009	0.601±0.121	0.766±0.119

Tablo VIII
TEST VERISINDE OLASILIK KALITESI, A, B VEYA C'DEN BIRIYLE EĞITIM (ÜÇ SEED ÜZERINDEN ORTALAMA ± STD). KALIBRATÖRLER YALNIZCA DOĞRULAMA VERISIYLE KURULUR.

Dedektör	Kalibratör	Aynı üretici			D: gpt-oss-120b			E: Gemini		
		Brier	ECE	NLL	Brier	ECE	NLL	Brier	ECE	NLL
Lexical-LR	Ham	0.035±0.001	0.167±0.002	0.190±0.002	0.201±0.004	0.316±0.015	0.569±0.009	0.073±0.003	0.243±0.005	0.292±0.008
Lexical-LR	Platt	0.002±0.003	0.004±0.002	0.014±0.020	0.271±0.077	0.299±0.075	1.823±0.427	0.015±0.016	0.026±0.019	0.054±0.055
Lexical-LR	Sıcaklık	0.003±0.004	0.006±0.005	0.025±0.033	0.353±0.048	0.380±0.023	2.899±1.656	0.030±0.008	0.050±0.012	0.135±0.050
Lexical-LR	İzotonik	0.003±0.002	0.006±0.002	0.017±0.019	0.242±0.050	0.289±0.055	2.037±0.524	0.015±0.012	0.036±0.022	0.057±0.047
RoBERTa	Ham	0.007±0.003	0.013±0.003	0.029±0.011	0.097±0.010	0.113±0.010	0.384±0.049	0.008±0.003	0.016±0.004	0.033±0.014
RoBERTa	Platt	0.008±0.005	0.010±0.005	0.059±0.046	0.170±0.098	0.181±0.096	1.772±1.409	0.020±0.016	0.024±0.015	0.202±0.197
RoBERTa	Sıcaklık	0.007±0.002	0.014±0.005	0.050±0.022	0.102±0.010	0.114±0.008	0.589±0.062	0.009±0.003	0.017±0.005	0.055±0.019
RoBERTa	İzotonik	0.008±0.005	0.010±0.006	0.077±0.066	0.158±0.094	0.177±0.095	1.906±1.375	0.020±0.014	0.026±0.015	0.227±0.197
Koordinatör	Ham	0.002±0.000	0.005±0.002	0.008±0.001	0.159±0.043	0.203±0.049	0.598±0.198	0.005±0.003	0.021±0.007	0.026±0.010
Koordinatör	Platt	0.002±0.001	0.004±0.003	0.015±0.011	0.184±0.067	0.202±0.072	1.303±0.621	0.006±0.002	0.011±0.002	0.024±0.011
Koordinatör	Sıcaklık	0.002±0.000	0.003±0.002	0.015±0.012	0.191±0.058	0.202±0.053	1.916±0.854	0.005±0.002	0.009±0.003	0.035±0.022
Koordinatör	İzotonik	0.002±0.000	0.004±0.002	0.014±0.014	0.173±0.055	0.208±0.059	1.492±0.684	0.006±0.003	0.015±0.007	0.030±0.020

Tablo IX
KARAR KURALININ ETKISI, A, B VEYA C'DEN BIRIYLE EĞITIM. BÜTÜN EŞIKLER DOĞRULAMA VERISINDE BELIRLENIR. SÖZDE GÖRÜLMEMIŞ KURAL, NE EĞITIMDE NE DE TESTTE BULUNAN YEREL ÜRETICILERIN DOĞRULAMA METINLERINI KULLANIR. İNSAN %1 VE %5 KURALLARI YALNIZCA DOĞRULAMA INSAN SKORLARINI KULLANIR.

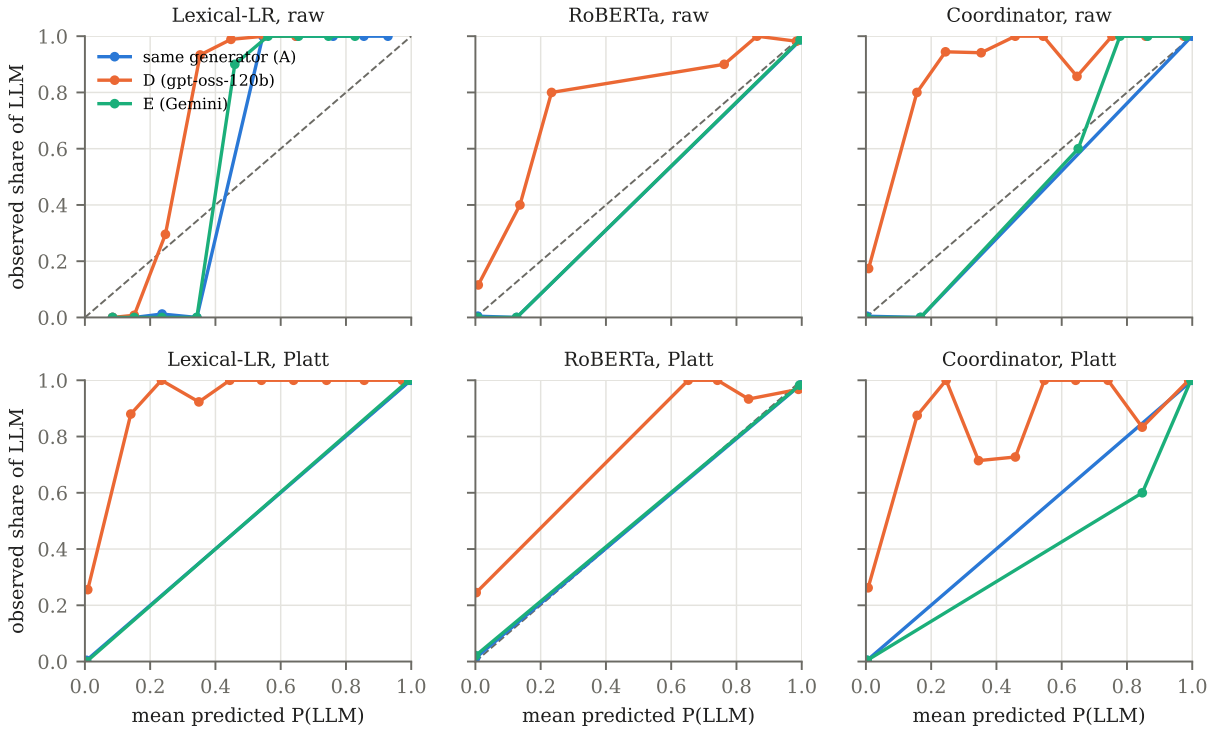
Dedektör	Eşik kuralı	F1, aynı	F1, çapraz	F1, D	Duyarlılık, D	F1, E	F1, dış	FPR, dış
Lexical-LR	Sabit 0.5	0.997±0.004	0.966±0.008	0.329±0.017	0.208	0.961±0.012	0.982±0.001	0.003
Lexical-LR	Doğrulama F1	0.997±0.003	0.978±0.019	0.502±0.099	0.363	0.980±0.025	0.983±0.005	0.016
Lexical-LR	Sözde görülmemiş F1	0.996±0.003	0.994±0.003	0.758±0.047	0.619	0.996±0.004	0.971±0.001	0.058
Lexical-LR	İnsan %5 FPR	0.986±0.017	0.986±0.016	0.886±0.018	0.823	0.987±0.017	0.905±0.019	0.212
Lexical-LR	İnsan %1 FPR	0.991±0.015	0.990±0.014	0.852±0.032	0.761	0.991±0.015	0.935±0.031	0.139
RoBERTa	Sabit 0.5	0.992±0.003	0.990±0.002	0.859±0.022	0.777	0.991±0.003	0.960±0.009	0.084
RoBERTa	Doğrulama F1	0.992±0.006	0.982±0.005	0.773±0.171	0.685	0.979±0.015	0.969±0.011	0.057
RoBERTa	Sözde görülmemiş F1	0.989±0.007	0.983±0.006	0.819±0.103	0.743	0.980±0.010	0.964±0.012	0.071
RoBERTa	İnsan %5 FPR	0.961±0.031	0.961±0.031	0.909±0.014	0.905	0.961±0.031	0.901±0.035	0.223
RoBERTa	İnsan %1 FPR	0.980±0.019	0.978±0.018	0.862±0.065	0.807	0.977±0.017	0.948±0.033	0.111
Koordinatör	Sabit 0.5	0.998±0.000	0.993±0.003	0.721±0.083	0.593	0.995±0.003	0.989±0.004	0.019
Koordinatör	Doğrulama F1	0.998±0.000	0.993±0.003	0.708±0.092	0.580	0.993±0.004	0.989±0.004	0.018
Koordinatör	Sözde görülmemiş F1	0.992±0.008	0.991±0.003	0.803±0.087	0.705	0.992±0.008	0.980±0.013	0.041
Koordinatör	İnsan %5 FPR	0.973±0.019	0.973±0.019	0.935±0.001	0.928	0.973±0.019	0.918±0.014	0.180
Koordinatör	İnsan %1 FPR	0.984±0.008	0.984±0.009	0.892±0.037	0.840	0.984±0.009	0.950±0.014	0.107

çıkarıyor. Hiç LLM metni kullanmayan iki insan yüzdeliği kuralı bu değeri 0.852 (%1 hedefi) ve 0.886 (%5 hedefi) düzeyine, Koordinatör'ünkini 0.721 düzeyinden 0.892 ve 0.935 düzeyine çıkarıyor. D skorlarının çoğu zaten 0.5'in üstünde olan RoBERTa daha az kazanıyor (0.859 düzeyinden 0.909 düzeyine).

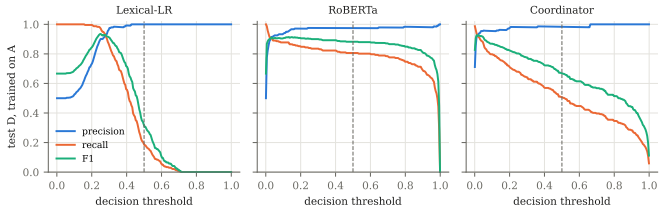
Bedeli diğer yayıncılarda görülüyor. Tablo IX tek üreticiyle eğitilen modeller için hesaplandı. Bu modeller sabit eşikte firma parçalarının yalnızca 0.003 (Lexical-LR) ve 0.019 (Koordinatör) kadarını işaretliyor, yani Tablo V'teki havuzlanmış modellerden çok daha azını. %5 kuralıyla bu oranlar 0.212 ve 0.180 oluyor. Firma insan metinleri CISA metinlerinden yüksek skor aldığı için CISA skorlarının bir yüzdeliği bunların daha çoğunu geçiriyor. Beş kuraldan D'yi en çok geri kazandıranlar, firma metinlerinde yanlış alarmı da en çok artıranlar. Havuzlanmış eğitimde gördüğümüz bedelin aynısı.

F. Koordinatör ne zaman yardımcı oluyor

Tablo X Koordinatör'ü 22 senaryonun hepsinde RoBERTa ile karşılaştırıyor. Referans RoBERTa, çünkü kayma altında en az kaybeden üye o. Aynı üreticide Lexical-SVM de Koordinatör kadar iyi (Tablo III). Koordinatör 13 senaryoda RoBERTa'dan iyi, 5 senaryoda kötü (Holm düzeltmeli $p < 0.05$). İkisinin de tavana yakın olduğu yerlerde kazanç küçük (aynı üretici 0.006, birini dışarıda bırak 0.010, yeniden ifade koşulları). Daha düşük yanlış pozitif oranının işe yaradığı firma



Şekil 7. A ile eğitilen modellerde ham (üst) ve Platt ölçeklenmiş (alt) olasılıkların güvenilirliği. Noktalar en az beş metin içeren kutular; kesikli köşegen kusursuz kalibrasyon.



Şekil 8. A ile eğitilen modellerde D üzerinde kesinlik, duyarlılık ve F1'in karar eşiğine göre değişimi; kesikli çizgi 0.5.

metinlerinde daha büyük (Microsoft 0.051, Mandiant 0.059). Kayıplar kanıtı en çok değiştiren kaymalarda: kelimelerinin dörtte biri LLM'den gelen metinler (-0.244), tek üreticiyle eğitimden sonra D (-0.138, %95 GA [-0.164, -0.113]), tek ajanlı metinler (-0.090), yarısı LLM'den gelen metinler (-0.053) ve üç üreticiyle eğitimden sonra D (-0.043).

Doğrulama verisinde yığın en çok Lexical-SVM (0.538) ve RoBERTa'ya (0.526), sonra Stilometri (0.312) ve Lexical-LR'ye (0.156) ağırlık veriyor. LLM Yargıç negatif ağırlık alıyor (-0.108). D'de Lexical-SVM'in ortalama logiti çöküyor. Katsayısıyla ağırlıklandırıldığında Koordinatör'ün düşüşünün 3.755 logit birimini açıklıyor. RoBERTa'nın payı 1.720, Stilometri'ninki 1.484. Eğitim üreticisinde kurulan ağırlıklar yani en çok güveni D'de başarısız olan bir üyeye veriyor. Doğrulamada en iyi tek üyeyi seçmek daha kötü sonuç veriyor (D'de F1 0.404; en sık seçilen üye Lexical-LR), logitlerin ağırlıksız ortalaması biraz daha iyi (0.754), eğitimde bulunmayan yerel üreticilerin doğrulama metinleriyle kurulan yığın en iyisi (0.824). Hiçbiri tek başına RoBERTa'ya (0.859) ulaşamıyor. İki sıfır örnekli dedektörü üye olarak eklemek pek bir şey değiştirmiyor (0.725). RoBERTa'yı Koordinatör'den çıkarmak D'deki F1 değerini 0.490 düzeyine düşürüyor. Başka herhangi bir üyeyi çıkarmak en çok 0.063 değiştiriyor (Tablo XI).

G. Ablasyonlar

Kurum adlarını maskelemek Lexical-LR'yi neredeyse hiç değiştirmiyor (aynı üreticide 0.996, üreticiler arası 0.967); *CISA* kelimesi log-odds listesinin başında olsa da dedektörler ona bağlı değil. Çıktı temizliğini kapatmak bir şey değiştirmiyor (0.997).

Uzunluğu eşleştirilmiş alt küme, uzunluğu insan parçasının %20 yakınında kalan LLM metinlerini tutuyor. A üreticisi neredeyse hiç bu kadar uzun yazmıyor (test kümesi başına yaklaşık 2 metin). Bu yüzden test kümesi başına 12 ve 23 metin bulunan B ve C'yi veriyoruz. Sözcüksel dedektörler ve RoBERTa etkilenmiyor (Lexical-LR 1.000 ve 1.000, RoBERTa 1.000 ve 0.992). Stilometri B'de 0.917 düzeyinden 0.764 düzeyine, C'de 0.947 düzeyinden 0.933 düzeyine düşüyor. Demek ki kısa yazan üreticilerde stilometrik sinyalin bir kısmını uzunluk taşıyor. Bu en açık B'de görülüyor ve alt kümeler küçük. Özellik grupları aynı cevabı daha büyük bir örnekte veriyor. Uzunluk ve noktalama özellikleri aynı üreticide 0.875 ve 0.823 veriyor, ama insan uzunluğunu tutturan D'de 0.482 ve 0.492. Tek başına sözcük çeşitliliği ise D'de 0.863 veriyor. Bu, tam stilometrik modelin verdiğinden (0.706) yüksek.

Bir Yazar şablonunu eğitimin dışında tutmak, Lexical-LR'nin o şablondaki duyarlılığını şablona göre 0.817 ile 1.000

Tablo X
BÜTÜN SENARYOLARDA EŞIK 0.5'TE ROBERTA, KOORDINATÖR VE TÜREVLERININ F1 DEĞERI (ÇALIŞTIRMALAR ÜZERINDEN ORTALAMA; ILK IKISINDE SEED'LER ÜZERINDEN ± STD). FARK, KOORDINATÖR EKSI ROBERTA; ARALIK KAYNAK DÜZEYINDE EŞLEŞTIRILMIŞ BOOTSTRAP ILE; * HOLM DÜZELTMELI $p < 0.05$. "GÖRÜLMEMIŞ YIĞIN" KOORDINATÖR'Ü EĞITIMDE OLMAYAN ÜRETICILERIN DOĞRULAMA METINLERIYLE KURAR. "ÇOK AJAN, AYNI KAYNAKLAR" TEK AJAN SATIRININ REFERANSIDIR.

Senaryo	RoBERTa	Koord.	Fark	%95 GA	Doğr. en iyi	Ort. logit	Görülm. yığın	+ sıfır örn.
Aynı üretici	0.992±0.003	0.998±0.000	+0.006*	[+0.002, +0.010]	0.996	0.998	0.994	0.998
Çapraz, yerel	0.990±0.002	0.993±0.003	+0.003	[-0.001, +0.007]	0.974	0.994	0.994	0.993
Birini dışarıda bırak	0.984±0.002	0.994±0.001	+0.010*	[+0.005, +0.017]	0.996	0.996	–	0.995
D, tek üretici	0.859±0.022	0.721±0.083	-0.138*	[-0.164, -0.113]	0.404	0.754	0.824	0.725
D, ABC	0.958±0.012	0.915±0.030	-0.043*	[-0.072, -0.018]	0.788	0.960	–	0.928
E, tek üretici	0.991±0.003	0.995±0.003	+0.004	[-0.001, +0.009]	0.966	0.995	0.994	0.993
E, ABC	0.979±0.003	0.996±0.004	+0.016*	[+0.006, +0.028]	0.987	0.998	–	0.996
Microsoft, ABC	0.927±0.012	0.978±0.022	+0.051*	[+0.046, +0.057]	0.945	0.962	–	0.981
Mandiant, ABC	0.910±0.017	0.969±0.007	+0.059*	[+0.051, +0.066]	0.949	0.945	–	0.974
Yalnız Yazar, ABC	0.979±0.003	0.996±0.004	+0.016*	[+0.010, +0.023]	0.987	0.998	–	0.996
Yeniden ifade, ABC	0.979±0.003	0.996±0.004	+0.016*	[+0.010, +0.023]	0.986	0.998	–	0.996
Yeniden ifade, başka model, ABC	0.979±0.003	0.996±0.004	+0.016*	[+0.010, +0.023]	0.986	0.998	–	0.996
İki kez yeniden ifade, ABC	0.979±0.003	0.996±0.004	+0.016*	[+0.011, +0.023]	0.986	0.998	–	0.996
Geri çeviri, ABC	0.975±0.003	0.994±0.006	+0.019*	[+0.012, +0.026]	0.985	0.996	–	0.993
"İnsanlaştır" promptu, ABC	0.979±0.003	0.995±0.002	+0.016*	[+0.010, +0.022]	0.987	0.998	–	0.995
Bildiri üslubu promptu, ABC	0.979±0.003	0.996±0.004	+0.017*	[+0.011, +0.023]	0.985	0.998	–	0.996
Az örnekli prompt, ABC	0.963±0.003	0.970±0.010	+0.007	[-0.002, +0.015]	0.961	0.980	–	0.974
Çok ajan, aynı kaynaklar, ABC	0.994±0.010	1.000±0.000	+0.006	[+0.000, +0.012]	0.994	1.000	–	1.000
Tek ajan, ABC	0.812±0.045	0.722±0.107	-0.090*	[-0.138, -0.049]	0.688	0.784	–	0.730
%25 LLM, ABC	0.518±0.041	0.274±0.184	-0.244*	[-0.278, -0.210]	0.370	0.333	–	0.263
%50 LLM, ABC	0.745±0.025	0.691±0.023	-0.053*	[-0.074, -0.035]	0.725	0.758	–	0.686
%75 LLM, ABC	0.896±0.014	0.910±0.007	+0.014*	[+0.004, +0.024]	0.922	0.938	–	0.910

Tablo XI
ABLASYONLAR, F1 (SEED'LER ÜZERINDEN ORTALAMA ± STD; A, B VEYA C'DEN BIRIYLE EĞITIM).

Koşul	Aynı üretici	Çapraz (A–C)	D	E
Yalnız TF-IDF (LR)	0.997 ± 0.004	0.966 ± 0.008	0.329 ± 0.017	0.961 ± 0.012
Yalnız stilometri (XGB)	0.934 ± 0.006	0.868 ± 0.004	0.706 ± 0.013	0.778 ± 0.022
TF-IDF + stilometri (LR)	0.964 ± 0.005	0.919 ± 0.010	0.735 ± 0.060	0.839 ± 0.021
LR, çıktı temizliği kapalı	0.997 ± 0.004	0.965 ± 0.008	0.336 ± 0.018	0.955 ± 0.012
LR, kurum adları maskeli	0.996 ± 0.004	0.967 ± 0.008	0.349 ± 0.016	0.964 ± 0.012
RoBERTa, kurum adları maskeli	0.988 ± 0.004	0.986 ± 0.002	0.901 ± 0.035	0.985 ± 0.007
Stilometri: yalnız uzunluk	0.875 ± 0.008	0.790 ± 0.004	0.482 ± 0.060	0.657 ± 0.039
Stilometri: yalnız sözcük çeşitliliği	0.845 ± 0.025	0.816 ± 0.024	0.863 ± 0.025	0.865 ± 0.033
Stilometri: yalnız noktalama	0.823 ± 0.012	0.771 ± 0.024	0.492 ± 0.055	0.590 ± 0.043
Stilometri: yalnız tekrar	0.800 ± 0.020	0.769 ± 0.024	0.825 ± 0.020	0.775 ± 0.037
Stilometri: yalnız POS	0.814 ± 0.038	0.755 ± 0.036	0.777 ± 0.052	0.850 ± 0.063
Koordinatör, tüm ajanlar	0.998 ± 0.000	0.993 ± 0.003	0.721 ± 0.083	0.995 ± 0.003
Koordinatör, Lexical-LR olmadan	0.998 ± 0.000	0.993 ± 0.003	0.727 ± 0.084	0.995 ± 0.003
Koordinatör, Lexical-SVM olmadan	0.996 ± 0.002	0.990 ± 0.008	0.784 ± 0.058	0.991 ± 0.002
Koordinatör, LLM Yargıç olmadan	0.999 ± 0.001	0.993 ± 0.004	0.732 ± 0.102	0.996 ± 0.004
Koordinatör, Stilometri olmadan	0.998 ± 0.002	0.994 ± 0.001	0.722 ± 0.125	0.992 ± 0.004
Koordinatör, RoBERTa olmadan	0.997 ± 0.003	0.972 ± 0.007	0.490 ± 0.094	0.960 ± 0.006

arasına düşürüyor; AUC değeri ise 1.000 olarak kalıyor. Metinleri sıralamak için tek bir şablona gerek yok, ama sabit eşikte şablonlar birbirinin yerine geçmiyor. Koordinatör'ün diğer yerel üreticilerdeki duyarlılığı konuya göre 0.978 ile 1.000 arasında. D'de en düşük duyarlılık zafiyet ve APT raporlarında (0.523 ve 0.537), en yüksek duyarlılık küçük "diğer" grubunda (0.926).

H. Maliyet

Çıkarım maliyeti metin başına Lexical-LR'de 1.7 ms ile LLM Yargıç'ta 1136.5 ms arasında değişiyor (Tablo XII). RoBERTa GPU'da 2.8 ms, Fast-DetectGPT 195.9 ms, Binoculars 725.0 ms istiyor. Üyeleri art arda çalıştırıldığında Koordinatör'ün maliyeti metin başına 1168.6 ms ve neredeyse tamamı Yargıç'tan geliyor. Yargıç olmadan 32.1 ms. Yargıç'ın negatif yığın ağırlığı ve çıkarılmasının sıfıra yakın etkisi, bu sürenin bizim verimizde karşılığının olmadığını gösteriyor.

I. Hata analizi

Kategoriler ne gösteriyor. Tablo XIV hata kategorilerini taban oranlarıyla birlikte veriyor. Lexical-LR'nin kaçırdığı D metinlerinin 76% kadarı kişisiz ve insan uzunluğunda. Ama bütün D metinlerinin 76% kadarı da öyle. Bu kategori D'nin nasıl yazdığını anlatıyor, kaçanları ayırmıyor. Kurum adı geçen D metinleri için de durum aynı. Taban oranından ayrılan iki kategori var. Birinci şahısla yazılmış D metinleri diğerlerinden daha az kaçıyor (Lexical-LR bunların 0.638 kadarını, kişisiz olanların 0.799 kadarını kaçırıyor). Analist olgularında bulunmayan teknik tanımlayıcılar içeren metinler ise daha çok kaçıyor. Bunlar D metinlerinin 4% kadarı, RoBERTa'nın

Tablo XII
MALIYET VE BAŞARIM, TEK EĞITIM ÜRETICISI. ÇIKARIM TEK BIR RTX 4060 DIZÜSTÜ GPU'DA, SABIT BIR ÖRNEK ÜZERINDE ÜÇ TEKRAR. KOORDINATÖR'ÜN MALIYETI ÜYELERININ ART ARDA ÇALIŞMA SÜRESININ TOPLAMIDIR; "EĞITIM" SÜTUNU EĞITILMEYEN LLM YARGIÇ'I IÇERMEZ.

Dedektör	ms/metin	Oran	GPU MiB	Eğitim s	F1, aynı	F1, D	AUC, D	F1, E
Lexical-LR	1.7	0.60	–	1	0.997	0.329	0.979	0.961
Lexical-SVM	2.0	0.72	–	1	0.998	0.327	0.983	0.969
Stilometri	25.6	9.27	–	0	0.934	0.706	0.878	0.778
RoBERTa	2.8	1.00	1269	20	0.992	0.859	0.982	0.991
LLM Yargıç	1136.5	410.75	16	–	0.504	0.499	0.533	0.628
Fast-DetectGPT	195.9	70.78	5771	–	0.744	0.540	0.699	0.427
Binoculars	725.0	262.02	5005	–	0.817	0.365	0.734	0.307
Koordinatör	1168.6	422.34	–	–	0.998	0.721	0.987	0.995

Tablo XIII
KAYNAĞA GÖRE ORTALAMA METIN ÖZELLIKLERI (A–E IÇIN ÇOK AJANLI METINLER). BIRINCI ŞAHIS VE KURUM ADI: EN AZ BIR BIRINCI ŞAHIS ZAMIRI VEYA KURUM ADI IÇEREN METINLERIN PAYI. İPUÇLARI: LEXICAL-LR'NIN IKI YÖNDE EN BÜYÜK AĞIRLIĞI VERDIĞI KELIME N-GRAM'LARININ 100 KELIMEDEKI GEÇIŞ SAYISI (A ILE EĞITILEN MODEL).

Kaynak	Kelime	MTLD	Özel ad	Birinci şahıs	Kurum adı	LLM yönlü ipucu	İnsan yönlü ipucu
İnsan (CISA)	279	86	0.118	14%	78%	0.85	6.16
A: Llama 3.1 8B	161	94	0.058	47%	10%	7.19	2.22
B: Qwen 2.5 7B	166	125	0.064	39%	11%	5.57	2.59
C: Mistral 7B	210	134	0.064	61%	17%	5.19	2.92
D: gpt-oss-120b	294	206	0.051	10%	13%	2.15	3.32
E: Gemini 3.1 Flash-Lite	279	170	0.035	45%	9%	3.60	2.27
İnsan (Microsoft)	312	95	0.063	77%	1%	1.43	3.69
İnsan (Mandiant)	295	93	0.078	74%	4%	1.77	3.57

Tablo XIV
BÜTÜN SEED'LER ÜZERINDEN HATA KATEGORILERI: HER DEDEKTÖRÜN HATALARININ SAYISI VE PAYI. KATEGORILER BIRBIRINI DIŞLAR VE UYAN ILK KURALA GÖRE ATANIR (BÖLÜM V-E); BIR METIN YANLIŞ SINIFLANDIRILDIĞI HER ÇALIŞTIRMADA BIR KEZ SAYILIR. "BÜTÜN METINLER", KATEGORININ GRUPTAKI HATALI YA DA HATASIZ BÜTÜN METINLER IÇINDEKI PAYIDIR; BIR KATEGORI ANCAK HATALAR IÇINDEKI PAYI BUNU AŞTIĞINDA HATALARDA FAZLA TEMSIL EDILIR. FN VE CISA SATIRLARI: TEK ÜRETICIYLE EĞITILEN MODELLER; FIRMA SATIRLARI: ABC ILE EĞITILEN MODELLER.

Hata	Kategori	Bütün metinler	Lexical-LR	RoBERTa	Koordinatör
FN, D	kişisiz, insan uzunluğunda	76%	429 (76%)	114 (72%)	211 (74%)
FN, D	kurum adı geçiyor	11%	60 (11%)	15 (9%)	28 (10%)
FN, D	birinci şahıs, yine de kaçırıldı	10%	44 (8%)	10 (6%)	22 (8%)
FN, D	olgularda olmayan teknik ayrıntı	4%	30 (5%)	19 (12%)	26 (9%)
FN, diğer üreticiler	birinci şahıs, yine de kaçırıldı	46%	44 (30%)	6 (46%)	11 (50%)
FN, diğer üreticiler	kişisiz, kısa	30%	43 (30%)	1 (8%)	2 (9%)
FN, diğer üreticiler	kurum adı geçiyor	7%	28 (19%)	5 (38%)	6 (27%)
FN, diğer üreticiler	kişisiz, insan uzunluğunda	17%	29 (20%)	1 (8%)	3 (14%)
FN, diğer üreticiler	olgularda olmayan teknik ayrıntı	0%	1 (1%)	0	0
FP, CISA	birinci şahıs	15%	0	3 (30%)	1 (50%)
FP, CISA	ürün açığı bildirimi	9%	0	3 (30%)	0
FP, CISA	az özel ad	19%	0	3 (30%)	0
FP, CISA	diğer	28%	0	1 (10%)	1 (50%)
FP, firma blogları	birinci şahıs	75%	170 (89%)	212 (91%)	61 (85%)
FP, firma blogları	az özel ad	16%	20 (11%)	19 (8%)	11 (15%)
FP, firma blogları	ürün açığı bildirimi	2%	0	2 (1%)	0

kaçırdıklarının ise 12% kadarı; RoBERTa bunların 0.633 kadarını, kişisiz olanların 0.212 kadarını kaçırıyor. Bu grup küçük (çalıştırma düzeyinde 30 durum) ve kural, zararsız açılımlarda da tetiklenen bir örüntü eşlemesi (Tablo XVI). Bu yüzden bunu bir işaret olarak okuyoruz: dosya adlarını ve tanımlayıcıları açık açık yazan bir metin bu dedektörlere bir insan bildirimine daha çok benziyor. Diğer üreticilerde az sayıdaki kaçırma, kurum adı geçen metinlerde yoğunlaşıyor (metinlerin 7% kadarı, RoBERTa'nın kaçırdıklarının 38% kadarı).

Kaçan ve yakalanan D metinleri. Tablo XV, çalıştırmaların en az yarısında kaçan D metinlerini kalanlarla karşılaştırıyor (Lexical-LR için 152 metne karşı 39, RoBERTa için 35 metne karşı 156). Kaçan metinler daha uzun (δ Lexical-LR'de 0.318, RoBERTa'da 0.250, Koordinatör'de 0.520) ve çeşitliliği daha düşük (tür-örnek oranında δ sırasıyla -0.389, -0.528 ve -0.656). Lexical-LR ve Koordinatör'de özel adları da daha çok ($\delta = 0.356$ ve 0.346); RoBERTa'da böyle bir fark yok (-0.019). Lexical-LR'de en büyük tek fark ipucu oranında. Kaçan metinler modelin LLM metniyle ilişkilendirdiği n-gram'lardan daha az ($\delta = -0.504$), insan metniyle ilişkilendirdiklerinden daha çok ($\delta = 0.276$) taşıyor. Regresyonda bir standart sapma fazla uzunluk, kaçırma olasılık oranını Lexical-LR'de 1.540 (%95 GA [1.187, 1.999]), RoBERTa'da 2.070, Koordinatör'de 2.624 katına çıkarıyor. Yüksek özel ad oranı

Tablo XV
YANLIŞ VE DOĞRU SINIFLANDIRILAN METINLERIN ÖZELLIKLERI: IKI GRUBUN ORTALAMALARI VE CLIFF δ DEĞERI (YANLIŞ SINIFLANDIRILANLARDA DAHA YÜKSEKSE POZITIF). BIR METIN, ÇALIŞTIRMALARIN EN AZ YARISINDA YANLIŞ SINIFLANDIRILDIYSA ILK GRUBA GIRER. *, BENJAMINI-HOCHBERG DÜZELTMELI $p < 0.05$ OLAN MANN-WHITNEY TESTINI GÖSTERIR. D: TEK ÜRETICIYLE EĞITILEN MODELLER; FIRMA PARÇALARI: ABC ILE EĞITILEN MODELLER.

Grup	Özellik	Lexical-LR		RoBERTa		Koordinatör	
		ortalamalar	δ	ortalamalar	δ	ortalamalar	δ
D, kaçan / yakalanan	Metin sayısı	152 / 39		35 / 156		90 / 101	
	Kelime	301 / 258	+0.32*	322 / 285	+0.25*	331 / 258	+0.52*
	MTLD	203 / 220	-0.25*	183 / 212	-0.37*	195 / 217	-0.34*
	Tür-örnek oranı (TTR)	0.680 / 0.718	-0.39*	0.647 / 0.696	-0.53*	0.654 / 0.717	-0.66*
	Özel ad oranı	0.055 / 0.038	+0.36*	0.052 / 0.052	-0.02	0.061 / 0.043	+0.35*
	Birinci şahıslı metin payı	0.08 / 0.18	-0.10	0.06 / 0.11	-0.05	0.09 / 0.11	-0.02
	100 kelimede LLM yönlü ipucu	2.01 / 3.16	-0.50*	1.69 / 2.37	-0.33*	1.91 / 2.55	-0.29*
	100 kelimede insan yönlü ipucu	3.43 / 2.85	+0.28*	3.85 / 3.19	+0.32*	3.47 / 3.17	+0.15
	Olgularda olmayan tanımlayıcı	0.07 / 0.00	+0.05	0.17 / 0.03	+0.09*	0.11 / 0.00	+0.09*
Firma, işaretlenen / geçen	Metin sayısı	64 / 374		79 / 359		15 / 423	
	Kelime	282 / 307	-0.32*	297 / 305	-0.13	249 / 306	-0.48*
	MTLD	108 / 92	+0.39*	109 / 91	+0.43*	121 / 93	+0.64*
	Tür-örnek oranı (TTR)	0.587 / 0.556	+0.42*	0.588 / 0.554	+0.38*	0.635 / 0.558	+0.76*
	Özel ad oranı	0.071 / 0.070	+0.01	0.060 / 0.072	-0.22*	0.060 / 0.071	-0.25
	Zamir oranı	0.035 / 0.035	+0.03	0.036 / 0.035	+0.09	0.039 / 0.035	+0.21
	100 kelimede birinci şahıs	1.47 / 0.86	+0.35*	1.44 / 0.84	+0.38*	1.19 / 0.94	+0.14
	100 kelimede LLM yönlü ipucu	2.44 / 1.44	+0.45*	2.31 / 1.43	+0.43*	2.16 / 1.57	+0.30
	100 kelimede insan yönlü ipucu	3.09 / 3.73	-0.28*	3.20 / 3.73	-0.25*	3.26 / 3.65	-0.20

Lexical-LR'de (1.723) ve Koordinatör'de (1.550) kaçırmayı artırıyor; RoBERTa'da açık bir etkisi yok (1.136, [0.892, 1.447]). Yüksek MTLD üçünde de kaçırma olasılığını düşürüyor (0.637, 0.532, 0.624). Şekil 9'in üst satırı aynı ilişkileri üçte birlik dilimlere göre kaçırma oranı olarak gösteriyor.

D neden kaçıyor, E neden kaçmıyor. D de E de büyük model ve ikisi de insan uzunluğunu tutturuyor. Aradaki farkı uzunluk açıklamıyor. Tablo XIII anlatım kipini ve sözcük seçimini gösteriyor. Birinci şahıs zamirleri D metinlerinin 10% kadarında geçiyor. Bu, CISA parçalarındakinden (14%) bile az. E metinlerinde oran 45%, yani yerel üreticilerin aralığında (39% ile 61% arası). Lexical-LR'nin LLM yönünde ağırlık verdiği n-gram'lar 100 kelimede D'de 2.146, E'de 3.596, yerel üreticilerde 5.189 ile 7.187 arasında geçiyor (CISA: 0.852). D, insan yönlü n-gram'ları da bütün üreticilerden çok kullanıyor (3.319). E insan uzunluğunda yazıyor ama küçük modellerin *we* ve *our* kullanımını ve tavsiye sözcüklerini koruyor. Bu modellerle eğitilen bir dedektör onu tanıyor. D ise kişisiz yazıyor, tanımlayıcıları tekrarlıyor ve okura seslenmiyor. Onu hâlâ LLM metni olarak ele veren şey sözcük çeşitliliği (medyan MTLD 199, CISA'da 84). Sözcük çeşitliliği özelliklerinin D'yi tek başına tam stilometrik modelden daha iyi bulması ve kaçanların en az çeşitli D metinleri olması bundan. Yazar şablonu da etkili. Lexical-LR olay müdahale raporu şablonuyla yazılmış D metinlerinin 0.917, SOC bülteni şablonuyla yazılmış olanların 0.671 kadarını kaçırıyor; RoBERTa'da firma blogu şablonu 0.305, SOC bülteni şablonu 0.114. Örnekleme sıcaklığının etkisi yok (Lexical-LR'de 0.7 için 0.776, 1.0 için 0.812).

Yanlış pozitifler. CISA test parçalarında Lexical-LR hiç yanlış pozitif yapmıyor; RoBERTa bütün çalıştırmalarda toplam 10 tane yapıyor: birinci şahısla yazılmış 3 parça, 3 ürün açığı bildirimi, az özel ad içeren 3 parça ve 1 başka parça. Bu sayılar betimlemenin ötesine geçmeye yetmiyor. Firma parçaları yeterli örnek veriyor (çalıştırma düzeyinde Lexical-LR'de 190, RoBERTa'da 233, Koordinatör'de 72 yanlış pozitif). Firma blogları kural olarak birinci şahısla yazıyor (Microsoft parçalarının 77%, Mandiant parçalarının 74% kadarı; CISA'da 14%) ve birinci şahıs kategorisi yanlış alarmlar içinde fazla temsil ediliyor (taban oranı 75% iken Lexical-LR'de 89%, RoBERTa'da 91%). Hangi parçaların işaretlendiğini Tablo XV ve Şekil 9'in alt satırı gösteriyor. İşaretlenenlerin çeşitliliği daha yüksek (MTLD için $\delta = 0.389$, 0.432 ve 0.637), 100 kelimede birinci şahıs kullanımı daha sık (0.354 ve 0.382), LLM yönlü ipuçları daha çok (0.447 ve 0.432); Lexical-LR ve Koordinatör'de ayrıca daha kısalar (-0.325 ve -0.480). Derlem düzeyinde firmaları CISA'dan ayıran genel zamir oranı, işaretlenen firma parçalarını geçenlerden ayırmıyor (0.028 ve 0.092). Özel ad oranı yalnızca RoBERTa'da ayırıyor (-0.220). Regresyonda bir standart sapma fazla birinci şahıs kullanımı yanlış alarm olasılık oranını Lexical-LR'de 1.595 (%95 GA [1.237, 2.058]), RoBERTa'da 1.754 katına çıkarıyor. Bir standart sapma fazla MTLD ise bu oranı sırasıyla 1.964 ve 1.987, Koordinatör'de 2.634 katına çıkarıyor.

Örnekler. Tablo XVI yüksek güvenle yapılmış altı hatayı gösteriyor. İlk D metni, olgularda CertUtil yazan yerde `certutil.exe` yazdığı için tanımlayıcı eklemiş sayılıyor. Bu, kuralın ne kadar kaba olduğunu gösteriyor. İkincisi SVR kısaltmasını "Federal Security Service" diye açıyor. Bu, başka bir Rus kurumunun (FSB) adı ve bir üslup dedektörünün göremeyeceği bir içerik hatası. İki CISA yanlış pozitifinden biri *we* ile yazılmış ortak bir bildirim, diğeri az ad içeren bir anlatı özeti.

Birlikte bakıldığında iki hata türü birbirinin ayna görüntüsü. Kaçan LLM metinleri uzun, kişisiz, özel adı bol ve sözcük çeşitliliği düşük metinler. Bu bir CISA parçasının profili. İşaretlenen insan metinleri daha kısa, birinci şahısla yazılmış ve sözcük çeşitliliği yüksek metinler. Bu da eğitim üreticilerinin profili.

Tablo XVI
YÜKSEK GÜVENLE YAPILAN HATALARA ÖRNEKLER (CISA PARÇALARI VE LLM ÇIKTISI); ÜRETICI, UZUNLUK VE METNI YANLIŞ SINIFLANDIRAN ÇALIŞTIRMALARDAKI ORTALAMA SKORLA BIRLIKTE.

Hata	Metnin başı
FN, Koordinatör: olgularda olmayan teknik ayrıntı. Üretici D, 341 kelime, ortalama P(LLM) 0.00	Malicious cyber actors have been observed deploying the KONNI malware family in campaigns that rely on a classic spear-phishing attachment workflow (ATT&CK T1566.001). The initial infection vector typically consists of a malicious Microsoft Office document that contains a Visual Basic for Applications (VBA) macro. When the recipient enables macros, the VBA code executes a chain of actions designed to establish…
FN, Koordinatör: kişisiz, insan uzunluğunda. Üretici D, 345 kelime, ortalama P(LLM) 0.07	The investigation began after the security operations center received an alert that an administrative account in the organization's cloud-based email environment had been used to modify permissions and access a number of privileged mailboxes. Log correlation and forensic analysis quickly revealed activity consistent with tactics employed by Russian Federal Security Service (SVR) cyber-espionage groups. The adversary's foothold was established through…
FN, Lexical-LR: kurum adı geçiyor. Üretici D, 317 kelime, ortalama P(LLM) 0.34	Malicious cyber actors-most likely advanced persistent threat (APT) groups-have been observed exploiting a series of critical VMware vulnerabilities disclosed in early 2022, specifically CVE-2022-22954, CVE-2022-22960, CVE-2022-22972, and CVE-2022-22973. These flaws enable a server-side template injection (SSTI) that can be leveraged to achieve remote code execution (RCE) on affected VMware products and, in many cases, to elevate privileges to the root…
FN, RoBERTa: birinci şahıs, yine de kaçırıldı. Üretici A, 122 kelime, ortalama P(LLM) 0.15	Malicious cyber actors, likely advanced persistent threat (APT) actors, have been exploiting critical vulnerabilities affecting VMware products. The vulnerabilities, specifically CVE-2022-22954 and CVE-2022-22960, were addressed by VMware with updates on April 6, 2022. The US Cybersecurity and Infrastructure Security Agency (CISA) added these vulnerabilities to its catalog of Known Exploited Vulnerabilities on April 14 and 15, 2022, respectively. Federal agencies…
FP, RoBERTa: birinci şahıs. CISA, 333 kelime, ortalama P(LLM) 0.61	Since early 2018, we have observed an increase in JBiFrost RAT being used in targeted attacks against critical national infrastructure owners and their supply chain operators. There has also been an increase in the RAT's hosting on infrastructure located in our countries. In early 2017, Adwind RAT was deployed via spoofed emails designed to look as if they originated from…
FP, RoBERTa: az özel ad. CISA, 309 kelime, ortalama P(LLM) 0.80	The BeagleBoyz use a variety of tools and techniques to gain access to a financial institution's network, learn the topology to discover key systems, and monetize their access. The technical analysis below represents an amalgamation of multiple known incidents, rather than details of a single operation. These findings are presented to highlight the group's ability to tailor their techniques to…

VII. TARTIŞMA

A. Araştırma sorularının yanıtları

S1, dilsel farklar. LLM yazımı CTI'da sözcük çeşitliliği daha yüksek, bigram tekrarı daha az. Adı geçen varlık daha az, okura verilen tavsiye daha çok. İnsan yazımı CTI tanımlayıcıları tekrarlıyor ve başka belgelere atıf yapıyor. Bu, üretilen metnin belirli tokenların uzun kuyruğundan kaçındığını söyleyen GLTR gözlemiyle örtüşüyor [12]. Bu özelliklerin hepsi insan yazarlığının kendisini anlatmıyor. Birinci şahısla anlatım CISA'yı hem küçük üreticilerden hem firma bloglarından ayırıyor, yani CISA'nın kurum üslubunu anlatıyor. Daha genel olan fark sözcük çeşitliliği. Üç insan yayıncısı MTLD'de birbirine yakın, B'den E'ye üreticiler bunların epey üstünde. Çeşitliliği en düşük üretici olan A ise firma bloglarıyla örtüşüyor (Tablo XIII).

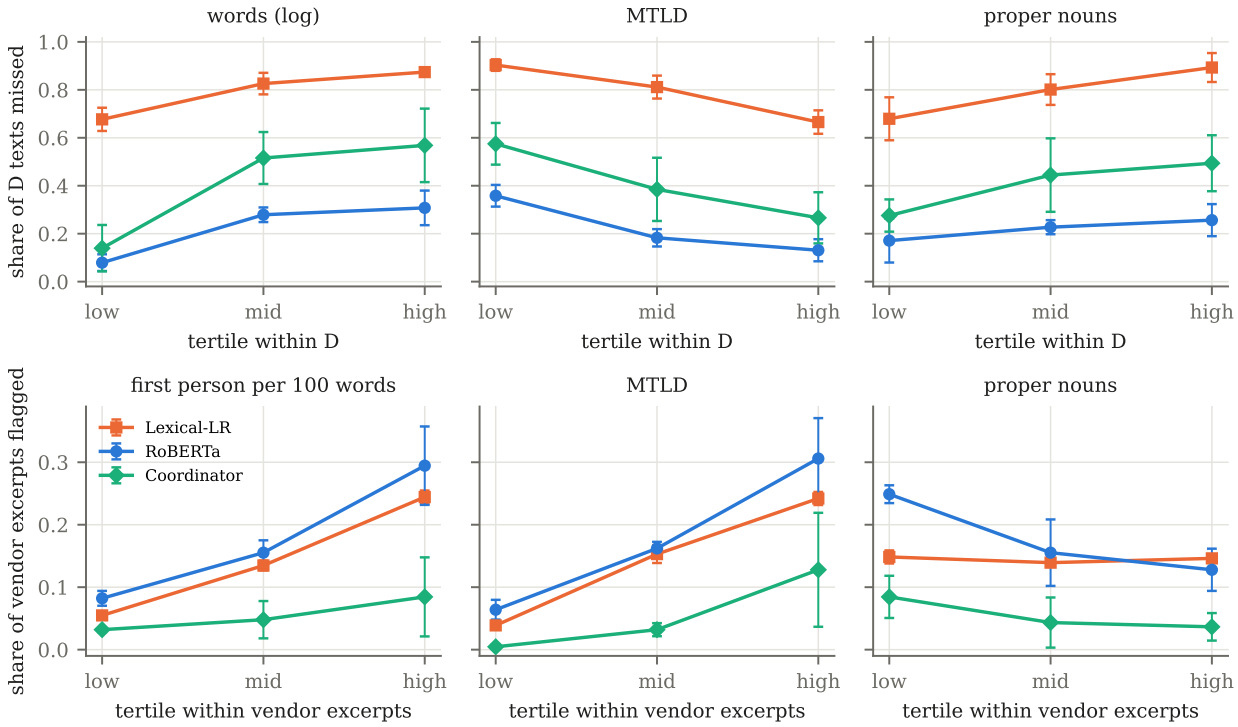
S2, baseline'lar ve transformer. Aynı üreticide bir TF-IDF baseline'ı RoBERTa kadar iyi. Fark kaymada ortaya çıkıyor. D'de RoBERTa'nın F1 değeri 0.859, Lexical-LR'ninki 0.329; RoBERTa bunun için kurum adlarına da muhtaç değil (adlar maskelenince 0.901). Önceden eğitilmiş temsiller, eğitim üreticilerinin n-gram'larının ötesinde LLM yazısına özgü bir şeyler yakalıyor görünüyor; GPT-2 için kurulan denetimli RoBERTa dedektörleri de böyleydi [14]. CTI verisi gerektirmeyen eğitimsiz dedektörler burada metinleri eğitilmiş her modelden çok daha kötü sıralıyor. 2.7B'lik bir puanlama modeli ve 4 bitlik 7B modellerle yazarlarının kurulumundan zayıflar. Üstelik RoBERTa'dan 70.8 ve 262.0 kat yavaşlar.

S3 ve S4, üretici üslubu ve üreticiler arası test. Üç 7–8B yerel model arasında üreticiler arası F1, aynı üreticideki değere yakın. Dedektörler yalnızca tek bir modelin üslubunu öğrenmiyor. Öğrendiklerinin bir kısmı ise küçük modellerin CTI yazma biçimine özgü: kısa, birinci şahısla ve okura tavsiye vererek. Gemini daha uzun yazıyor ama bu anlatımı koruyor ve yakalanıyor. gpt-oss-120b bu anlatımı bırakıyor ve sözcüksel modeller onu kaçırıyor; AUC değerleri ise yüksek kalıyor. M4 ve RAID'de görülmemiş üreticilerin metninin insan yazımı sayılması da bu örüntü [4], [5]. Eşik sonuçlarımız sorunun kararda olduğunu gösteriyor, hata analizi de hangi özelliklerin işe karıştığını söylüyor.

S5, önemli özellikler. Stilometrik model çoğunlukla uzunluğa (en önemli özellik: n_words) ve özel ad oranına, sözcüksel model zamirlere, kaçamak kelimelere ve kurum adlarına bakıyor. Uzunluk ipucu büyük üreticilere taşınmıyor. Sözcük çeşitliliği ipucu taşınıyor; D içinde kaçanlar da uzun, çeşitliliği düşük ve özel adı bol metinler.

S6, konular ve saldırı türleri. Yerel üreticiler arasında duyarlılık konuya bağlı değil. D'de zafiyet ve APT raporları oltalama ve fidye yazılımı raporlarından daha çok kaçıyor (0.523 ve 0.537; diğerlerinde 0.667 ve 0.633). Olası bir neden, bu raporların olgularının çoğunlukla aktör, ürün ve CVE adlarından oluşması ve bunun üretilen metnin özel ad oranını yükseltmesi. Konu etiketleri anahtar kelime kurallarından geliyor ve çalıştırmalar arasındaki standart sapmalar büyük. Bunu bir eğilim olarak okuyoruz.

S7, LLM teknolojisindeki değişim. 2024 dönemi 7–8B modellerle eğitilen dedektörler en çok, daha büyük ve yeni olan gpt-oss-120b'de kaybediyor. Aynı modellerin başka bir yöntemle ürettiği metinlerde, tek ajanlı yeniden yazımda ve cümle düzeyinde karıştırmada da başarısız oluyorlar. Yeniden ifade iki dedektör grubunu farklı etkiledi. Genel alan çalışmalarında olduğu gibi [7], [8] olabilirliğe dayalı iki dedektörün duyarlılı-



Şekil 9. Bir metin özelliğinin üçte birlik dilimlerine göre hata oranı (seed'ler üzerinden ortalama ve standart sapma). Üst: tek üreticiyle eğitilen modellerin kaçırdığı D metinlerinin payı. Alt: ABC ile eğitilen modellerin işaretlediği Microsoft ve Mandiant insan parçalarının payı.

ğını düşürdü, eğitilmiş olanlarınkini değiştirmedi. Akla yatkın bir açıklama, yeniden ifade için aynı küçük talimat modellerini kullanmış olmamız. Yeniden ifade edilmiş metin o zaman aynı alışkanlıkları taşıyan başka bir LLM metni oluyor ve bu tür metinlerle eğitilmiş bir sınıflandırıcı, token olasılıkları değişse de onu tanıyor. RADAR'daki gibi tespitten kaçmak üzere eğitilmiş bir yeniden ifade modeli [18] daha zorlu bir sınama olurdu.

B. Sıralama ve karar

Üretici ve yayıncı kaymasında denetimli dedektörlerin AUC değeri 1'e yakın kaldı. Değişen F1 ya da yanlış pozitif oranıydı. Yeni metinle karşılaşan bir dedektör onu çoğunlukla hâlâ doğru sıralayabiliyor. Bozulan, eğitim üreticilerine ve eğitim yayıncısına göre kurulmuş sınır. Dağılım içi doğrulama verisiyle kalibrasyon bunu onarmıyor; Ovadia ve arkadaşlarının bulgusu da bu yönde [27]. Görülmemiş bir üretici için işe yarayan iki onarım, insan skorlarından belirlenen eşik ve birkaç üreticiyle eğitim, sınırı insan metnine doğru kaydırıyor ve ikisinin de bedeli modelin görmediği bir yayıncıda ödeniyor. Lexical-LR'nin Microsoft parçalarındaki yanlış pozitif oranı, bir yerine üç üreticiyle eğitildiğinde 0.003 değerinden 0.152 değerine çıkıyor. İki kaymanın neden ters yönlere çektiğini hata analizi söylüyor. Dedektörler CISA'yı küçük üreticilerden uzunluk, birinci şahısla anlatım ve sözcük çeşitliliği üzerinden ayırıyor. İlk iki özellikte CISA'nın yakınında duran görülmemiş bir üretici kaçıyor. Son iki özellikte üreticilerin yakınında duran görülmemiş bir yayıncı işaretleniyor. Bu özellikler üzerindeki tek bir sınır ikisine birden yetmiyor. Bu bedeli ödetmeyen çare, birden fazla yayıncının insan metniydi. Bir firmanın parçalarını (231 veya 207 parça ve LLM sürümleri) eğitime eklemek, diğer firmadaki yanlış pozitif oranını birkaç kat düşürdü.

C. Ajanları birleştirmek ne zaman işe yarıyor

Yığınlanmış Koordinatör, üyeleri farklı yerlerde yanıldığında işe yarıyor. Firma metinlerinde yanlış pozitif oranı Lexical-LR ve RoBERTa'nınkinin yarısından az. En çok güvendiği üye başarısız olduğunda ise RoBERTa'nın gerisinde kalıyor. Tek üreticiyle eğitimden sonra D'de olan bu. Ağırlıklar bütün üyelerin güvenilir göründüğü yerde kuruluyor, bu yüzden yığın hangi üyenin yeni koşula taşınacağını bilemiyor. Ağırlıkları benzetilmiş bir kayma altında öğrenmek kaybın bir kısmını geri getiriyor ve bu açıklamayı destekliyor. Uygulamada birleştirme kuralı dışarıda tutulmuş üreticiler ve yayıncılar üzerinde seçilmeli. Buradaki LLM Yargıç gibi maliyet ekleyip sinyal eklemeyen üyeler de çıkarılmalı.

D. Bir CTI iş akışında kullanım

Gelen raporların ön elemesinde bizim verimizdeki en iyi tek seçenek ince ayarlı bir kodlayıcı. GPU'da çıkarımı bir TF-IDF modeli kadar ucuz, üretici kaymasında duyarlılığının çoğunu koruyor ve LLM ile yeniden ifadeye aldanmıyor. Zayıf noktaları, yalnızca ilk 256 tokenı gördüğü kısmi üretim ve tanımadığı yayıncılardaki yanlış alarmlar. Bu yüzden skoru bir raporu engellemek için değil analiste yönlendirmek için kullanılmalı, uzun raporlar pencere pencere puanlanmalı ve her yeni rapor kaynağının insan metni, dedektöre o kaynakta güvenmeden önce eğitime eklenmeli. Gerçek bir rapordan

adları ve tanımlayıcıları kopyalayan sahte raporlar (tek ajanlı metinlerimiz gibi) ve insan ile üretilmiş paragrafları karıştıran raporlar en büyük açık olarak kalıyor.

VIII. Sınırlılıklar ve Geçerlilik Tehditleri

A. Veri seti

Eğitim yayıncısı. Bütün eğitim metni CISA'dan geliyor. Bu yüzden eğitimde "insan" aynı zamanda "bu kurumun yazım üslubu" anlamına geliyor. Microsoft ve Mandiant kümeleri bu yanlılığın ne kadar taşındığını ölçüyor, ancak bunlar yayıncı etiketleri ve başlık kurallarıyla seçilmiş firma blogları ve 80 artı 80 kaynak, firma yazımının küçük bir örneği. STIX nesneleri, analist yazışmaları veya İngilizce olmayan raporlar gibi başka CTI biçimleri kapsanmıyor. *Boyut.* 203 CISA kaynağı seed başına yaklaşık 40 kaynaklık test kümeleri veriyor. Ortalamaların yanında kaynak düzeyindeki aralıkları da bu yüzden veriyoruz. Bazı alt kümeler çok daha küçük: tek ajanlı test metinleri, uzunluğu eşleştirilmiş alt kümeler ve taban oranı düşük hata kategorileri. *Tarihler.* İnsan yazarlığı 30 Kasım 2022 veya öncesindeki yayın tarihlerine dayanıyor. CISA sayfaları revizyon tarihini gösteriyor, Microsoft üst verileri bir site taşımasıyla değişmiş ve Mandiant yazıları yeni bir sunucuya taşınmış. Bu yüzden belgeleri bildirim kodlarına, URL tarihlerine ve görünür yazar satırlarına göre tarihliyor ve sonraki güncellemeleri duyuran paragrafları siliyoruz. Tarih sınırından sonra böyle bir not olmadan değiştirilmiş bir paragraf fark edilmezdi. *Dışarıda kalan sayfalar.* Yerel antivirüs gömülü zararlı yazılım örneklerini işaretlediği için 6 CISA analiz raporu okunamadı.

B. Üretim

Üretici kapsamı. Üç eğitim üreticisi 2024'ten 7–8B boyutunda açık modeller. D ve E yalnızca çok ajanlı koşulda ve kota kısıtlamasından önce üretilenler dışında yalnızca test parçaları için var. Bu yüzden daha büyük modellerle eğitim yapamıyor, tek ajanlı yeniden yazımı ve dış yayıncıları bu modellerle sınayamıyoruz. D ile E arasındaki karşıtlık her türden tek bir modele dayanıyor. *Tek hat.* Bütün LLM metinleri tek bir prompt kümesinden ve tek bir Analist'ten geliyor. Tek ajan ve prompt stratejisi koşulları başka bir yöntemin sonuçları değiştirdiğini gösteriyor. *Olgu kayması.* Üreticiler bazen olguları değiştirdi veya ekledi. Bu metinler ayıklanmadı ve alan bilgisi olan bir okur bazılarını içerikten fark edebilir. Eklenen tanımlayıcılar için kullandığımız ölçü bir örüntü eşlemesi. Uydurulmuş anlatıyı yakalamıyor. *İnsan tarafından düzenlenmiş metin yok.* Bir saldırgan bir LLM taslağını bir insana düzelttirebilir. Bu tür metinleri toplamadık ve başka bir LLM ile taklit etmemeyi seçtik, çünkü bu yine LLM yeniden yazımını ölçmek olurdu. Cümle düzeyindeki karışımlar, insan ve makine paragraflarından derlenmiş bir rapora yaklaşıyor, makine metninin insan tarafından düzenlenmesine değil; LLM etiketleri de bir kabul.

C. Dedektörler ve analiz

Model seçimi. RoBERTa tek ince ayarlı kodlayıcı, Gemma 2 9B tek yargıç. Hiperparametre araması yapılmadı. Binoculars 4 bit hassasiyetle ve skorlarını kaydıran kırpılmış bir gözlemci dağılımıyla, Fast-DetectGPT tek bir 2.7B modelle çalıştı. İkisi de yazarlarının en güçlü ayarlarından küçük; Ghostbuster çalıştırılamadı. *Kalibrasyon verisi.* Kalibratörler ve eşikler seed başına 20 civarında kaynaktan oluşan doğrulama kümelerinden geliyor. Kırk kadar insan skorunun 99. yüzdeliği en büyük skora yakın; %1 kuralı CISA test metninde 0.018 ile 0.040 arasında yanlış pozitif oranı veriyor. *Hata analizi.* Kategoriler kural tabanlı, tek bir yazar tarafından tanımlanmış ve ikinci bir işaretleyiciyle kontrol edilmemiş. Özellik karşılaştırmaları ve regresyonlar gözlemsel: hangi metinlerin yanlış sınıflandırıldığını gösteriyorlar, bir özelliği değiştirmenin kararı değiştireceğini kanıtlamıyorlar. İpucu listeleri A ile eğitilen tek bir modelden geliyor. *İstatistik.* Bootstrap aralıkları test kaynaklarını yeniden örnekliyor, ancak üç seed'i ve eğitim üreticilerini veri olarak alıyor. Farklı bir üretici seçiminin varyansını yansıtmıyor. p değerleri $2/2001$ değerinden küçük olamıyor.

IX. Sonuç

İnsan ve LLM yazımı CTI ölçülebilir biçimde farklı ve üretici biliniyorsa bunları ayırmaya bir TF-IDF modeli yetiyor. Zorluk, dedektörün görmediği metinle başlıyor. Beş üreticinin aynı çıkarılmış olgulardan yazdığı derlemimizde dedektörler bu metinleri doğru sıralamayı sürdürdü, kararı ise kaybetti: kişisiz yazan büyük ve görülmemiş bir üretici eşiğin altında, birinci şahısla yazılmış firma blogları eşiğin üstünde skor aldı. Eğitim üreticilerini havuzlamak ya da eşiği insan skorlarından belirlemek ilk hatayı onardı, ikincisini büyüttü. Doğrulama verisiyle kalibrasyon ikisini de onarmadı. Bu bedeli ödetmeyen tek çare, eğitime ikinci bir yayıncının insan metnini katmaktı. Dedektör ajanlarının yığınlanmış birleşimi firma metinlerinde maliyetine değdi, en çok güvendiği üyenin çöktüğü yerde RoBERTa'nın gerisinde kaldı. Bir LLM metnini bir LLM ile yeniden yazmak onu eğitilmiş dedektörlerden gizlemedi. Kaynağı okuyarak yeniden yazmak ve insan cümleleriyle üretilmiş cümleleri karıştırmak ise gizledi. Çalışma, eğitim için tek bir devlet yayıncısıyla, üç küçük eğitim üreticisiyle ve tek bir üretim hattıyla sınırlı. İnsan tarafından düzenlenmiş LLM taslakları, daha büyük eğitim üreticileri ve uzun raporların pencere pencere puanlanması sonraki adımlar.

Yeniden Üretilebilirlik

Kod, yapılandırma dosyaları, CISA derlemi, üretilen bütün metinler ve ajan mesajları, tahminler ve sonuç tabloları proje reposunda yer alıyor.[1] Her aşama tek bir komutla çalışıyor, `python -m src.cli <aşama> --config <dosya>`; `experiments/run_all.sh` hepsini sırayla çalıştırıyor. Model adları, promptlar, örnekleme sıcaklıkları, seed'ler ve dedektör ayarları `configs/` içinde. Paket sürümleri `requirements.txt` içinde sabitlenmiş. Bu makaledeki her sayı rapor aşaması tarafından bir makro dosyasına yazılıyor. Böylece metin sonuçlardan kopamıyor. Microsoft ve Mandiant parçaları toplama betiği tarafından listelenen URL'lerden yeniden oluşturuluyor ve kayıtlı özetlerle (hash) karşılaştırılıyor.

[1] https://github.com/FurkanDevelops/llm-cti-detection

API üretimleri (D, E) birebir tekrarlanamadığı için çıktıları saklanıyor.

Kaynaklar

[1] P. Ranade, A. Piplai, S. Mittal, A. Joshi, and T. Finin, "Generating fake cyber threat intelligence using transformer-based models," in *2021 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2021, p. 1–9. [Online]. Available: http://dx.doi.org/10.1109/IJCNN52387.2021.9534192

[2] H. Huang, N. Sun, M. Tani, Y. Zhang, J. Jiang, and S. Jha, "Can llm-generated misinformation be detected: A study on cyber threat intelligence," *Future Generation Computer Systems*, vol. 173, p. 107877, Dec. 2025. [Online]. Available: http://dx.doi.org/10.1016/j.future.2025.107877

[3] J. Qian, X. Zhang, S. Cheng, and Z. Li, "GLM-based fake cybersecurity threat intelligence detection models and algorithms," *Applied Sciences*, vol. 15, no. 19, p. 10755, 2025.

[4] Y. Wang, J. Mansurov, P. Ivanov, J. Su, A. Shelmanov, A. Tsvigun, C. Whitehouse, O. Mohammed Afzal, T. Mahmoud, T. Sasaki, T. Arnold, A. F. Aji, N. Habash, I. Gurevych, and P. Nakov, "M4: Multi-generator, multi-domain, and multi-lingual black-box machine-generated text detection," in *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2024, p. 1369–1407. [Online]. Available: http://dx.doi.org/10.18653/v1/2024.eacl-long.83

[5] L. Dugan, A. Hwang, F. Trhlík, A. Zhu, J. M. Ludan, H. Xu, D. Ippolito, and C. Callison-Burch, "Raid: A shared benchmark for robust evaluation of machine-generated text detectors," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2024, p. 12463–12492. [Online]. Available: http://dx.doi.org/10.18653/v1/2024.acl-long.674

[6] J. Wu, R. Zhan, D. F. Wong, S. Yang, X. Yang, Y. Yuan, and L. S. Chao, "DetectRL: Benchmarking LLM-generated text detection in real-world scenarios," in *Advances in Neural Information Processing Systems*, vol. 37, 2024, pp. 100 369–100 401.

[7] K. Krishna, Y. Song, M. Karpinska, J. Wieting, and M. Iyyer, "Paraphrasing evades detectors of AI-generated text, but retrieval is an effective defense," in *Advances in Neural Information Processing Systems*, vol. 36, 2023. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2023/hash/575c450013d0e99e4b0ecf82bd1afaa4-Abstract-Conference.html

[8] V. S. Sadasivan, A. Kumar, S. Balasubramanian, W. Wang, and S. Feizi, "Can ai-generated text be reliably detected?" 2023. [Online]. Available: https://arxiv.org/abs/2303.11156

[9] W. Liang, M. Yuksekgonul, Y. Mao, E. Wu, and J. Zou, "Gpt detectors are biased against non-native english writers," *Patterns*, vol. 4, no. 7, p. 100779, 2023. [Online]. Available: http://dx.doi.org/10.1016/j.patter.2023.100779

[10] G. Bao, Y. Zhao, Z. Teng, L. Yang, and Y. Zhang, "Fast-DetectGPT: Efficient zero-shot detection of machine-generated text via conditional probability curvature," in *The Twelfth International Conference on Learning Representations*, 2024. [Online]. Available: https://arxiv.org/abs/2310.05130

[11] A. Hans, A. Schwarzschild, V. Cherepanova, H. Kazemi, A. Saha, M. Goldblum, J. Geiping, and T. Goldstein, "Spotting LLMs with Binoculars: Zero-shot detection of machine-generated text," in *Proceedings of the 41st International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 235, 2024, pp. 17 519–17 537. [Online]. Available: https://arxiv.org/abs/2401.12070

[12] S. Gehrmann, H. Strobelt, and A. Rush, "Gltr: Statistical detection and visualization of generated text," in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics: System Demonstrations*. Association for Computational Linguistics, 2019, p. 111–116. [Online]. Available: http://dx.doi.org/10.18653/v1/P19-3019

[13] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "Roberta: A robustly optimized bert pretraining approach," 2019. [Online]. Available: https://arxiv.org/abs/1907.11692

[14] I. Solaiman, M. Brundage, J. Clark, A. Askell, A. Herbert-Voss, J. Wu, A. Radford, G. Krueger, J. W. Kim, S. Kreps, M. McCain, A. Newhouse, J. Blazakis, K. McGuffie, and J. Wang, "Release strategies and the social impacts of language models," 2019. [Online]. Available: https://arxiv.org/abs/1908.09203

[15] Y. Wang, J. Mansurov, P. Ivanov, J. Su, A. Shelmanov, A. Tsvigun, O. M. Afzal, T. Mahmoud, G. Puccetti, T. Arnold *et al.*, "SemEval-2024 task 8: Multidomain, multimodel and multilingual machine-generated text detection," in *Proceedings of the 18th International Workshop on Semantic Evaluation*, 2024, pp. 2057–2079.

[16] E. Mitchell, Y. Lee, A. Khazatsky, C. D. Manning, and C. Finn, "DetectGPT: Zero-shot machine-generated text detection using probability curvature," in *Proceedings of the 40th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 202, 2023, pp. 24 950–24 962. [Online]. Available: https://proceedings.mlr.press/v202/mitchell23a.html

[17] V. Verma, E. Fleisig, N. Tomlin, and D. Klein, "Ghostbuster: Detecting text ghostwritten by large language models," in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Association for Computational Linguistics, 2024, p. 1702–1717. [Online]. Available: http://dx.doi.org/10.18653/v1/2024.naacl-long.95

[18] X. Hu, P.-Y. Chen, and T.-Y. Ho, "RADAR: Robust AI-text detection via adversarial learning," in *Advances in Neural Information Processing Systems*, vol. 36, 2023. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2023/hash/30e15e5941ae0cdab7ef58cc8d59a4ca-Abstract-Conference.html

[19] X. Qu and X. Meng, "TM-TREK at SemEval-2024 task 8: Towards LLM-based automatic boundary detection for human-machine mixed text," in *Proceedings of the 18th International Workshop on Semantic Evaluation*, 2024, pp. 710–715.

[20] D. H. Wolpert, "Stacked generalization," *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992.

[21] I. Ong and B. K. Quek, "Applying ensemble methods to model-agnostic machine-generated text detection," 2024. [Online]. Available: https://arxiv.org/abs/2406.12570

[22] Y. Wang, L. Wei, and Y. Wang, "CAMF: Collaborative adversarial multi-agent framework for machine generated text detection," 2025. [Online]. Available: https://arxiv.org/abs/2508.11933

[23] J. Li, M. Ye, C. Peng, X. Yin, and X. Wan, "AGENT-X: Adaptive guideline-based expert network for threshold-free AI-generated text detection," 2025. [Online]. Available: https://arxiv.org/abs/2505.15261

[24] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: https://proceedings.mlr.press/v70/guo17a.html

[25] J. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*. MIT Press, 1999.

[26] B. Zadrozny and C. Elkan, "Transforming classifier scores into accurate multiclass probability estimates," in *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2002, pp. 694–699.

[27] Y. Ovadia, E. Fertig, J. Ren, Z. Nado, D. Sculley, S. Nowozin, J. Dillon, B. Lakshminarayanan, and J. Snoek, "Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift," in *Advances in Neural Information Processing Systems*, vol. 32, 2019. [Online]. Available: https://arxiv.org/abs/1906.02530

[28] M. P. Naeini, G. Cooper, and M. Hauskrecht, "Obtaining well calibrated probabilities using Bayesian binning," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 29, no. 1, 2015.

[29] P. M. McCarthy and S. Jarvis, "Mtld, vocd-d, and hd-d: A validation study of sophisticated approaches to lexical diversity assessment," *Behavior Research Methods*, vol. 42, no. 2, p. 381–392, May 2010. [Online]. Available: http://dx.doi.org/10.3758/BRM.42.2.381

[30] S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979. [Online]. Available: https://www.jstor.org/stable/4615733

[31] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.

[32] B. L. Monroe, M. P. Colaresi, and K. M. Quinn, "Fightin' words: Lexical feature selection and evaluation for identifying the content of political conflict," *Political Analysis*, vol. 16, no. 4, p. 372–403, 2008. [Online]. Available: http://dx.doi.org/10.1093/pan/mpn018